

第六章 样本及抽样分布


§0 从概率到数理统计

§1 随机样本

§2 直方图、分位数与箱线图

§3 抽样分布

§0 从概率到数理统计





数理统计的研究内容

- 怎样有效地收集、整理和分析带有随机性的数据
- 如何量化不确定性
- 怎样对所考察的问题作出推断或预测
- 为决策和行动提供依据和建议


数理统计——解释现象背后的规律

- 大量随机现象必然呈现出它的规律性，因而从理论上讲，只要对随机现象进行足够多次观察，被研究的随机现象的规律性一定能清楚地呈现出来
- ✓ 福尔摩斯“跳舞的小人”中的字母分布规律



数理统计——解释现象背后的规律

- 大量随机现象必然呈现出它的规律性，因而从理论上讲，只要对随机现象进行足够多次观察，被研究的随机现象的规律性一定能清楚地呈现出来
 - ✓ 福尔摩斯“跳舞的小人”中的字母分布规律
 - ✓ “模仿游戏”中“电报中固定位置密文的固定含义” Wetter(天气) “
 - ✓ 信号的盲检测



数理统计——解释现象背后的规律

- 大量随机现象必然呈现出它的规律性，因而从理论上讲，只要对随机现象进行足够多次观察，被研究的随机现象的规律性一定能清楚地呈现出来
- 只对随机现象进行次数不多的观察试验——只是局部观察资料
 - ✓ 数理统计的任务就是研究怎样有效地收集、整理、分析所获得的有限的资料
 - ✓ 对所研究的问题，尽可能地作出精确而可靠的结论

数理统计的基本方法

两个基本方法

- 参数估计

根据数据, 用一些方法对分布的未知参数进行
估计

- 假设检验

根据数据, 用一些方法对分布的未知参数进行
检验

统计推断的两个重要基础

- 收集数据——从总体 $X \sim F(x)$ 抽取样本
 $X_1, X_2, \dots, X_n$
- 加工整理数据——统计量

§1 随机样本

一、基本概念

1. **总体**——试验的全部可能的观察值称为总体
 - 一个总体对应一个随机变量
 - 对总体的研究就是对一个随机变量 X 的研究
 - X 的分布函数和数字特征就称为总体的分布函数和数字特征
 - 总体可以是具体事物的集合，如一批产品，也可以是关于事物的度量数据集合，如长度测量
2. **个体**——总体中的每个可能观察值称为个体
 - 个体是随机试验的观察值
 - 总体中的个体，应当有共同的可观察的特征
 - 该特征与研究目的有关

总体	个体	特征
一批产品	每件产品	等级
一批灯泡	每个灯泡	寿命
一年的日空气质量	每天的日空气质量	PM2.5
数轴上某一线段	线段中每一点	坐标
一批彩票	每张彩票	号码
全国人口寿命	每个人的寿命	寿命

3. 容量——总体中包含个体的数量称为总体容量

有限总体与无限总体

容量有限的总体称为有限总体，容量无限的称为无限总体

某工厂10月份生产的灯泡寿命所组成的总体中，个体的总数就是10月份生产的灯泡数，这是一个有限总体

该工厂生产的所有灯泡寿命所组成的总体是一个无限总体，它包括以往生产和今后生产的灯泡寿命

当有限总体包含的个体的总数很大时，可近似地将它看成是无限总体

4. 总体分布——我们把数量指标取不同数值的比率叫做总体分布

例1. 在2000名大学一年级学生的年龄中, 年龄指标值为“15”, “16”, “17”, “18”, “19”, “20”的依次有9, 21, 132, 1207, 588, 43名
总体就是数集 {15, 16, 17, 18, 19, 20}
总体分布为:

年龄	15	16	17	18	19	20
比率	$\frac{9}{2000}$	$\frac{21}{2000}$	$\frac{132}{2000}$	$\frac{1207}{2000}$	$\frac{588}{2000}$	$\frac{43}{2000}$

5. 样本

- 设 X 是具有分布函数 F 的随机变量，若 $X_1, X_2, \dots, X_n$ 是具有同一分布函数 F 、相互独立的随机变量，则称 $X_1, X_2, \dots, X_n$ 为从分布函数 F (或总体 F 、或总体 X)得到的容量为 n 的简单随机样本，简称样本
- 观察值 $x_1, x_2, \dots, x_n$ 称为样本值，又称为 X 的 n 个独立的观察值
- 样本中所含个体的个数，称为样本容量

二、样本选取

选取样本的目的——从样本的特征对总体特征做出估计和推断。因此，抽样必须尽可能多地反映总体的特征。

选取样本是需要考虑的因素：

- (1)独立性：抽样时互不影响。
- (2)代表性：样本的分布与总体相同

抽样方式：

- (1)不重复抽样(不放回)
- (2)重复抽样(放回)

简单随机抽样

- 获得简单随机样本的抽样方法称为简单随机抽样
- 一般地，对于有限总体采用放回抽样就能得到简单随机样本；当总体的个数比样本容量大的多时，可将不放回抽样近似地当成放回抽样

简单随机抽样

由定义, 若 $X_1, X_2, \dots, X_n$ 为 F 的一个样本, 则 $X_1, X_2, \dots, X_n$ 的联合分布函数为

$$F^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

若设 X 的分布律为 $P\{X = x\} = p(x)$, 则 $(X_1, X_2, \dots, X_n)$ 的联合分布律为

$$P\{X_1 = x_1, \dots, X_n = x_n\} = \prod_{i=1}^n p(x_i)$$

又若 X 具有概率密度 f , $X_1, X_2, \dots, X_n$ 的联合概率密度为

$$f^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

例2. 设总体 X 服从参数为 $\lambda (\lambda > 0)$ 的指数分布,
 $(X_1, X_2, \dots, X_n)$ 是来自总体的样本, 求样本
 $(X_1, X_2, \dots, X_n)$ 的概率密度。

解: 总体 X 的概率密度为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

因为 $X_1, X_2, \dots, X_n$ 相互独立, 且与 X 有相同的分布,
所以 $(X_1, X_2, \dots, X_n)$ 的概率密度为

$$\begin{aligned} f_n(x_1, x_2, \dots, x_n) &= \prod_{i=1}^n f(x_i) \\ &= \begin{cases} \lambda^n e^{-\lambda \sum_{i=1}^n x_i}, & x_i > 0 \\ 0, & \text{其他} \end{cases} \end{aligned}$$

例3. 设总体 X 服从两点分布 $B(1, p)$, 其中 $0 < p < 1$, $(X_1, X_2, \dots, X_n)$ 是来自总体的样本, 求样本 $(X_1, X_2, \dots, X_n)$ 的分布律。

解: 总体 X 的分布律为

$$P\{X = i\} = p^i(1 - p)^{1-i}, \quad (i = 0, 1)$$

所以 $(X_1, X_2, \dots, X_n)$ 的分布律为

$$\begin{aligned} &P\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} \\ &= p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}, \end{aligned}$$

其中, $x_1, x_2, \dots, x_n$ 在集合 $\{0, 1\}$ 中取值。

例4. 若 $X_1, X_2, \dots, X_n$ 是参数为 λ 的泊松分布总体 X 的样本, 求 $(X_1, X_2, \dots, X_n)$ 的联合分布律。

解: 总体 X 的分布律为

$$p(x) = P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda}, \quad x = 0, 1, 2, \dots$$

所以 $(X_1, X_2, \dots, X_n)$ 的联合分布律为

$$\begin{aligned} P\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} &= \prod_{i=1}^n p(x_i) \\ &= \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} e^{-n\lambda}, \\ &\quad x_i = 0, 1, \dots, i = 1, 2, \dots, n \end{aligned}$$

例5. 若 $X_1, X_2, \dots, X_n$ 是总体 $X \sim N(\mu, \sigma^2)$ 的样本, 求 $(X_1, X_2, \dots, X_n)$ 的联合概率密度。

解: 总体 X 的概率密度为:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty$$

于是 $(X_1, X_2, \dots, X_n)$ 的联合概率密度

$$\begin{aligned} f(x_1, x_2, \dots, x_n) &= \prod_{i=1}^n f(x_i) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} = \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} e^{-\frac{\sum_{i=1}^n (x_i-\mu)^2}{2\sigma^2}}, \\ &\quad -\infty < x_i < +\infty, i = 1, 2, \dots, n \end{aligned}$$


概念对比——概率、统计

概率	数理统计
样本空间	总体
随机事件	样本
样本点	个体

§2 直方图、分位数与箱线图

一、直方图


- 数值分布的一种图形化表示手段，可以很好地表达概率分布，便于从总体上把握分布
- 由Karl Pearson在1895年首次引入




在图像中的应用



Size: $\sim 2000 * 3000$



在图像中的应用




下图的直方图



Size: ~1000* 1500




Size: ~1000* 1500



上图的直方图


在图像中的应用




下图的直方图



Sobel 垂直边缘




Sobel 垂直边缘




上图的直方图

Histogram of Oriented Gradients (HOG)

图像HOG特征
提取流程：



Histogram of Oriented Gradients (HOG)



左: x方向梯度值
中: y方向梯度值
右: 梯度幅值



80	36	5	10	0	64	90	73
37	9	9	179	78	27	169	166
87	136	173	39	102	163	152	176
76	13	1	168	159	22	125	143
120	70	14	150	145	144	145	143
58	86	119	98	100	101	133	113
30	65	157	75	78	165	145	124
11	170	91	4	110	17	133	110



Gradient Direction

2	3	4	4	3	4	2	2
5	11	17	13	7	9	3	4
11	21	23	27	22	17	4	6
23	99	165	135	85	32	26	2
91	155	133	136	144	152	57	28
98	196	76	38	26	60	170	51
165	60	60	27	77	85	43	136
71	13	34	23	108	27	48	110

Gradient Magnitude



Histogram of Gradients




2	3	4	4	3	4	2	2
5	11	17	13	7	9	3	4
11	21	23	27	22	17	4	6
23	99	165	135	85	32	26	2
91	155	133	136	144	152	57	28
98	196	76	38	26	60	170	51
165	60	60	27	77	85	43	136
71	13	34	23	108	27	48	110

Gradient Magnitude


80	36	5	10	0	64	90	73
37	9	9	179	78	27	169	166
87	136	173	39	102	163	152	176
76	13	1	168	159	22	125	143
120	70	14	150	145	144	145	143
58	86	119	98	100	101	133	113
30	65	157	75	78	165	145	124
11	170	91	4	110	17	133	110

Gradient Direction

Histogram of Oriented Gradients (HOG)



一个cell中的
直方图



Block归一化



二、分位数

设有容量为 n 的样本观察值 $x_1, x_2, \dots, x_n$, 样本的 p 分位数($0 < p < 1$)记为 x_p , 它具有以下性质:

- (1) 至少有 np 个观察值小于或等于 x_p ;
- (2) 至少有 $n(1 - p)$ 个观察值大于或等于 x_p

将 $x_1, x_2, \dots, x_n$ 排序, 保证 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

$$x_p = \begin{cases} x_{(\lceil np \rceil)}, & np \text{不是整数} \\ \frac{1}{2} [x_{(np)} + x_{(np+1)}], & np \text{为整数} \end{cases}$$


$p = 0.5$ 时 $x_{0.5}$ 记为 Q_2 或 M ，称为**样本中位数**，即

$$x_{0.5} = \begin{cases} x_{(\lceil \frac{n}{2} \rceil)}, & n \text{ 是奇数} \\ \frac{1}{2} [x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}], & n \text{ 是偶数} \end{cases}$$

$x_{0.25}$ 记为 Q_1 ，称为**第一四分位数**， $x_{0.75}$ 记为 Q_3 ，称为**第三四分位数**

三、箱线图

箱线图由最小值Min、第一四分位数 Q_1 、样本中位数 M 、第三四分位数 Q_3 和最大值Max构成



由箱线图可以看出数据集的以下性质：中心位置，散布程度，对称性

四分位数间距——第一四分位数 Q_1 与第三四分位数 Q_3 的间距，记为**IQR (Interquartile Range)**

如果数据小于 $Q_1 - 1.5IQR$ 或大于 $Q_3 + 1.5IQR$ ，而认为异常，此时的箱线图就需要做出修正，排除异常值

例6. 下面是21个病人住院的时间(天), 试画出修正的箱线图

1, 2, 3, 3, 4, 4, 5, 6, 6, 7, 7, 9, 9, 10, 12, 12, 13, 15, 18, 23, 55

解: $M=7$ ($[21 * 0.5] = 11th$),

$Q_1 = 4$ ($[21 * 0.25] = 6th$)

$Q_3 = 12$ ($[21 * 0.75] = 16th$)

$Min=1$, $Max=55$, $IQR = 8$,

$Q_1 - 1.5IQR = -8$, $Q_3 + 1.5IQR = 24$

于是 "55" 是Outlier, 修正最大值



§3 抽样分布

统计推断的两个重要基础

收集数据——从总体 $X \sim F(x)$ 抽取样本
 $X_1, X_2, \dots, X_n$

加工整理数据——统计量

一、统计量

定义(统计量): 若 $X_1, X_2, \dots, X_n$ 是来自总体 X 的一个样本, $g(X_1, X_2, \dots, X_n)$ 是 $X_1, X_2, \dots, X_n$ 的函数, 若 g 中**不含任何未知参数**, 则称 $g(X_1, X_2, \dots, X_n)$ 是一统计量。

关于统计量的一些理解:

- 统计量是由随机变量组成的随机样本的函数, **不含任何未知参数**
- 注意: 统计量是**随机变量**,
- 于是 $x_1, x_2, \dots, x_n$ 是相应于样本 $X_1, X_2, \dots, X_n$ 的样本值, 而称 $g(x_1, x_2, \dots, x_n)$ 是 $g(X_1, X_2, \dots, X_n)$ 的观察值

例7. 设 $X_1, X_2, \dots, X_n$ 为来自总体 $X \sim N(\mu, \sigma^2)$ 的一个样本, 其中 μ 未知, σ^2 已知, 问下列随机变量中那些是统计量。

$$\frac{X_1 + X_2}{2};$$

$$\frac{X_1 + \dots + X_n}{n} - \mu;$$

$$\frac{(X_1 + X_2)^2}{\sigma^2}$$

常用统计量

样本均值

反映了总体均值
的信息

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

反映了总体方差
的信息

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

样本标准差

$$S = \sqrt{\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)}$$

常用统计量

样本 k 阶原点矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots$$

反映了总体 k 阶矩的信息

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, \quad k = 1, 2, \dots$$

反映了总体 k 阶中心矩的信息

上述统计量与数字特征的差异

- 统计量是随机变量
- 数字特征是常数

对应观察值

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

$$s = \sqrt{\frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)}$$

$$a_k = \frac{1}{n} \sum_{i=1}^n x_i^k, b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, \quad k = 1, 2, \dots$$

若总体 X 的 k 阶矩 $E(X^k)$ 记为 μ_k 存在, 则当 $n \rightarrow \infty$ 时,

$$A_k \xrightarrow{P} \mu_k, k = 1, 2, \dots$$

证明: $X_1, X_2, \dots, X_n$ 独立且与 X 同分布,

于是 $X_1^k, X_2^k, \dots, X_n^k$ 独立且与 X^k 同分布,

从而有

$$E(X_1^k) = E(X_2^k) = \dots, = E(X_n^k) = \mu_k$$

由Khinchin大数定律:

$$A_k \xrightarrow{P} \mu_k, k = 1, 2, \dots$$

进一步, 由依概率收敛的序列性质知道, 若 g 为连续函数, 则有

$$g(A_1, A_2, \dots, A_k) \xrightarrow{P} g(\mu_1, \mu_2, \dots, \mu_k)$$

矩估计法的基础

概念对比——概率、统计、计算机科学

概率	数理统计	计算机科学(PR&ML)
样本空间	总体	
随机事件	样本	训练样本集
样本点	个体	单个样本
方差	方差	类内距离
	估计	学习

二、经验分布函数

——与总体分布函数 $F(x)$ 相对应的统计量

设 $X_1, X_2, \dots, X_n$ 是总体 F 的一个样本。用 $S(x)$, $-\infty < x < +\infty$ 表示 $X_1, X_2, \dots, X_n$ 中不大于 x 的随机变量个数, 定义经验分布函数为:

$$F_n(x) = \frac{1}{n} S(x), -\infty < x < +\infty$$

例8. 设总体 F 具有一个样本值1, 2, 3, 经验分布函数 $F_3(x)$ 的观察值

$$F_3(x) = \begin{cases} 0, & \text{若 } x < 1, \\ \frac{1}{3}, & \text{若 } 1 \leq x < 2 \\ \frac{2}{3}, & \text{若 } 2 \leq x < 3 \\ 1, & \text{若 } x \geq 3 \end{cases}$$

例9. 设总体 F 具有一个样本值1, 1, 2, 经验分布函数 $F_3(x)$ 的观察值

$$F_3(x) = \begin{cases} 0, & \text{若 } x < 1, \\ \frac{2}{3}, & \text{若 } 1 \leq x < 2 \\ 1, & \text{若 } x \geq 2 \end{cases}$$

一般地, 设 $x_1, x_2, \dots, x_n$ 是总体 F 的一个样本值, 先将 $x_1, x_2, \dots, x_n$ 按自小到大排序, 并重新编号满足:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

则经验分布函数 $F_n(x)$ 的观察值为:

$$F_n(x) = \begin{cases} 0, & \text{若 } x < x_{(1)} \\ \frac{k}{n}, & \text{若 } x_{(k)} \leq x < x_{(k+1)} \\ 1, & \text{若 } x \geq x_{(n)} \end{cases}$$

对于经验分布函数 $F_n(x)$, 格里汶科1933年证明了:

对一切实数 x , 当 $n \rightarrow \infty$ 时, $F_n(x)$ 以概率1一致收敛于分布函数 $F(x)$, 即:

$$P \left\{ \lim_{n \rightarrow \infty} \sup_{-\infty < x < +\infty} |F_n(x) - F(x)| = 0 \right\} = 1$$