


§0 回顾——从概率到数理统计



数理统计的研究内容

- 怎样有效地收集、整理和分析带有随机性的数据
- 如何量化不确定性
- 怎样对所考察的问题作出推断或预测
- 为决策和行动提供依据和建议



大数定律的一般形式

设 $\{X_n\}, n = 1, 2, \dots$, 是一个随机变量序列, 而且对每个 n , $E(X_n)$ 存在, 如果对于任意给定的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| < \epsilon \right\} = 1$$

则称随机变量序列 $\{X_n\}$ 服从大数定律.

等价形式:

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| \geq \epsilon \right\} = 0$$

$$\text{即 } \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

定义：设 $X_1, X_2, \dots, X_n, \dots$ 是独立的随机变量序列，若 $E(X_k), D(X_k)$ ($k = 1, 2, \dots$)都存在，令

$$Y_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n E(X_k)}{\sqrt{\sum_{k=1}^n D(X_k)}}$$

若对任意 $x \in R$ ，有，

$$\lim_{n \rightarrow \infty} P\{Y_n \leq x\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

则称该随机变量序列服从中心极限定理

等价地，若 $\{X_n\}$ 服从中心极限定理，则当 n 足够大时 Y_n 近似服从标准正态分布

大数定律的关系

大数定律的一般形式

对随机变量序列 $\{X_n\}$ ($n = 1, 2, \dots$), $E(X_n)$ 存在,

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

← 不要求独立同分布

Khinchin大数定律

$X_1, X_2, \dots, X_n, \dots$ 独立同分布,
 $E(X_k) = \mu, (k = 1, 2, \dots)$

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

Bernoulli试验

Bernoulli大数定律

n 次独立重复试验发生
 f_A 次, p 是每次试验中
发生的概率

$$\frac{f_A}{n} \xrightarrow{P} p$$

不要求
方差的
存在性

Bernoulli试验

Poisson大数定律

n 次独立试验发生 f_A 次,
第 k 次发生概率为 p_k

$$\frac{n_A}{n} \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n p_k$$

0-1分布

不要求独立
性, 但对方
差有约束

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

$$\lim_{n \rightarrow \infty} D\left(\frac{1}{n} \sum_{k=1}^n X_k\right) = 0 \text{ (Markov条件)}$$

Markov大数定律

随机变量序列 $\{X_n\}$, $E(X_n)$ 存在, 且

Chebyshev大数定律

$X_1, X_2, \dots, X_n, \dots$ 两两相互独立
 $E(X_n)$ 、 $D(X_k)$ 存在 ($k = 1, 2, \dots$)

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

独立同分布

独立同分布下的 Chebyshev大数定律

$E(X_k) = \mu, D(X_k)$ 存在
($k = 1, 2, \dots$)

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

三个中心极限定理

Lyapunov定理

$\{X_n\}$ 独立, 且 $E(X_k) = \mu_k$, $D(X_k) = \sigma_k^2 > 0$,
 $B_n^2 = \sum_{k=1}^n \sigma_k^2$,

若存在 $\delta > 0$, 使得当 $n \rightarrow \infty$ 时

不要求同分布,
但要求方差满足收敛性

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{|X_k - \mu_k|^{2+\delta}\} \rightarrow 0$$
$$\lim_{n \rightarrow \infty} Z_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n} \sim N(0,1)$$

独立同分布的中心极限定理

$\{X_n\}$ 独立同分布, 且 $E(X_k) = \mu$,
 $D(X_k) = \sigma^2 > 0$, ($k = 1, 2, \dots$),

$$\lim_{n \rightarrow \infty} Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \sim N(0,1)$$

二项分布逼近

De Moivre – Laplace定理

$\eta_n \sim b(n, p)$ ($0 < p < 1$), 则对于任意 x , 有

$$\lim_{n \rightarrow \infty} \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1)$$

抽样分布

三种重要的统计学分布

- χ^2 分布主要是用于列联分析
- t 分布主要是用于小样本分析
- F 分布主要是用于方差分析

四个重要的抽样定理

定理1. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $X \sim N(\mu, \sigma^2)$ 的样本, 则

$$\bar{X} \sim N(\mu, \sigma^2/n)$$

定理2. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $X \sim N(\mu, \sigma^2)$ 的样本, $\bar{X}$ 和 S^2 分别为样本均值与样本方差, 则有

$$(1) \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

(2) $\bar{X}$ 和 S^2 相互独立

定理3. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $X \sim N(\mu, \sigma^2)$ 的样本, $\bar{X}$ 和 S^2 分别为样本的均值与样本方差, 则有

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n - 1)$$

定理4. 设 $X_1, X_2, \dots, X_n$ 与 $Y_1, Y_2, \dots, Y_n$ 分别是来自总体 $X \sim N(\mu_1, \sigma_1^2)$ 和 $Y \sim N(\mu_2, \sigma_2^2)$ 的样本, 且两样本分别独立, 两样本均值与样本方差分别为 $\bar{X}, \bar{Y}, S_1^2, S_2^2$, 则有

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时,

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2),$$

其中

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}, \quad S_w = \sqrt{S_w^2}$$

第七章 参数估计

§1 点估计

§2 估计量的评选标准

§1 点估计

参数估计与非参数估计

- 参数估计——总体分布的类型是已知的，通过样本估计其中的未知参数
- 非参数估计——总体分布的类型是未知的，通过样本估计总体的分布

点估计问题

设总体 X 的分布函数 $F(x, \theta)$ 的形式已知(例如: 正态分布), θ 是待估计参数(例如: 期望 μ)。

$X_1, X_2, \dots, X_n$ 是 X 的一个样本, $x_1, x_2, \dots, x_n$ 是相应的样本值。

构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 来估计未知参数 θ , 称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的估计量, $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的估计值

这种对未知参数进行定值估计的问题就是点估计问题

概念区分：

- 估计量与估计值
 - 估计量是统计量，因而是随机变量
 - 估计值则是一个标量或向量
- 在不会导致混淆的情况下，统称估计量与估计值为未知变量 θ 的估计
- 由于估计量是样本的函数，是随机变量，故对不同的样本值，得到的参数值往往不同，如何构造和求解估计量是关键问题

常用构造估计量的方法

- 矩估计法
- 最大似然估计法
- 贝叶斯估计法

矩估计法

若 X 为连续型随机变量, 其概率密度函数为

$$f(x; \theta_1, \theta_2, \dots, \theta_k)$$

若 X 为离散型随机变量, 其分布律为

$$P\{X = x\} = P(x; \theta_1, \theta_2, \dots, \theta_k)$$

其中, $\theta_1, \theta_2, \dots, \theta_k$ 是待估计参数, $X_1, X_2, \dots, X_n$ 为来自 X 的样本。

设相应的 l 阶矩 $E[X^l] = \mu_l$ 存在, $l = 1, 2, \dots, k$

则 $\mu_l = \mu_l(\theta_1, \theta_2, \dots, \theta_k), l = 1, 2, \dots, k$

从样本获得的相应的 l 阶矩为

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l, \quad l = 1, 2, \dots, k$$

于是有包含 $\theta_1, \theta_2, \dots, \theta_k$ 的联立方程组,

$$\begin{cases} A_1 = \mu_1(\theta_1, \theta_2, \dots, \theta_k) \\ A_2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k) \\ \dots \dots \\ A_k = \mu_k(\theta_1, \theta_2, \dots, \theta_k) \end{cases}$$

从中解出方程组的解, 记为 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$, 即

$$\begin{cases} \hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_k) \\ \hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_k) \\ \dots \dots \\ \hat{\theta}_k = \hat{\theta}_k(X_1, X_2, \dots, X_k) \end{cases}$$

用 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 分别作为 $\theta_1, \theta_2, \dots, \theta_k$ 的估计量, 这种利用矩求估计量的方法称为矩估计法, 这种估计量称为**矩估计量**; 相应的观察值称为**矩估计值**

矩估计法的理论分析

由于 $X_1, X_2, \dots, X_n$ 相互独立, 且与总体 X 同分布,
于是有 $X_1^l, X_2^l, \dots, X_n^l$ 相互独立, 且与总体 X^l 同分布,
故有

$$E(X_1^l) = E(X_2^l) = \dots = E(X_n^l) = \mu_l, l = 1, 2, \dots, k$$

由辛钦大数定律知

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l \xrightarrow{P} \mu_l, \quad l = 1, 2, \dots, k$$

因此可以假设

$$A_l = \mu_l, \quad l = 1, 2, \dots, k$$

用 A_l 估计 μ_l

独立同分布的随机变量序列 $\{X_n\}$, 且具有数学期望 $E(X_k) = \mu, (k = 1, 2, \dots)$, 则有

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

矩估计法求估计量的步骤:

1. 求 $\mu_1 = E[X]$ ($\mu_2 = E[X^2], \dots$)
2. 设 $A_1 = \mu_1$ ($A_2 = \mu_2, \dots$)
3. 解上面的方程(组), 得 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_k),$
($\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_k), \dots$)

例1. 设某炸药厂一天中发生着火现象的次数 X 服从参数为 λ 的泊松分布($P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$), λ 未知, 样本如下:

着火的次数 k	0	1	2	3	4	5	6	
发生 k 次着火天数 n_k	75	90	54	22	6	2	1	$\sum = 250$

试用矩估计估计参数 λ 。

解: 因为泊松分布有: $\mu_1 = E[X] = \lambda$

样本的一阶矩为:

$$A_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

$$\text{则 } \hat{\lambda} = \bar{X} = \frac{1}{250} (0 \times 75 + 1 \times 90 + \cdots + 6 \times 1) = 1.22$$

于是 λ 的估计值 $\hat{\lambda} = 1.22$

例2. 设总体 $X \sim U[a, b]$, a, b 未知, $X_1, X_2, \dots, X_n$ 是一个样本, 求 a, b 的矩估计量。

解: $\mu_1 = E[X] = \frac{a+b}{2}$

$$\mu_2 = E[X^2] = D[X] + (E[X])^2 = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4}$$

可以令,
$$\begin{cases} A_1 = \frac{a+b}{2} \\ A_2 = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4} \end{cases}$$

导出:
$$\begin{cases} a+b = 2A_1 \\ b-a = \sqrt{12(A_2 - A_1^2)} \end{cases}$$

解得

$$\begin{cases} \hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \\ \hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \end{cases}$$

另外，注意对样本方差的有偏估计

$$A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

例3. 设总体 X 的均值 μ 、方差 σ^2 均存在, 且 $\sigma^2 > 0$, 但 μ 、 σ^2 未知, $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本。求 μ 、 σ^2 的矩估计量。

解: $\mu_1 = E[X] = \mu$

$$\mu_2 = E[X^2] = D[X] + (E[X])^2 = \sigma^2 + \mu^2$$

令, $\mu_1 = A_1, \mu_2 = A_2$

即有
$$\begin{cases} \mu = A_1 \\ \sigma^2 + \mu^2 = A_2 \end{cases}$$

于是解得

$$\begin{cases} \hat{\mu} = A_1 = \bar{X} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \end{cases}$$

例4. 设总体 X 服从参数为 λ 的指数分布, 其中 $\lambda > 0$ 未知, $X_1, X_2, \dots, X_n$ 是一个样本, 试求参数 λ 的矩估计。

解: 总体 X 的密度函数为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

于是

$$E[X] = \int_{-\infty}^{+\infty} x f(x) dx = \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

令 $\bar{X} = 1/\lambda$

于是得到 λ 的矩估计量为

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

例5. 设总体 X 的密度函数为

$$f(x) = \begin{cases} (\alpha + 1)x^\alpha, & 0 < x < 1 \\ 0, & otherwise \end{cases}$$

其中 $\alpha > 0$ 为未知参数, 试求参数 α 的矩估计量。

解:

$$E[X] = \int_0^1 x(\alpha + 1)x^\alpha dx = \frac{\alpha + 1}{\alpha + 2}$$

于是令,

$$\bar{X} = \frac{\alpha + 1}{\alpha + 2}$$

由此解得 α 的矩估计量为:

$$\hat{\alpha} = \frac{2\bar{X} - 1}{1 - \bar{X}}$$

最大似然估计(Maximum Likelihood Estimation, MLE)

问题引出

实例1. 已知某盒中装有一些黑球和白球，不知道哪种球多，但知道它们的数目比是1:2。从中有放回地抽取5个球，发现黑球有2只，白球3只。问盒中哪种球多？

设 X 表示抽取的5个球中黑球的数目，则 $X \sim B(5, p)$

由于数目比为1:2，因此 $p = 1/3$ 或 $p = 2/3$ 。

$$\text{若 } p = 1/3, \text{ 则 } P(X = 2) = C_5^2 \left(\frac{1}{3}\right)^2 \left(\frac{2}{3}\right)^3 = \frac{80}{243}$$

$$\text{若 } p = 2/3, \text{ 则 } P(X = 2) = C_5^2 \left(\frac{2}{3}\right)^2 \left(\frac{1}{3}\right)^3 = \frac{40}{243}$$

据此，认为 $p = 1/3$ ，则黑球数目少。

最大似然估计

基本假设：

设某一随机试验共有 $A_1, A_2, \dots, A_k, \dots$ 若干种可能结果，若在一次试验中 A_m 出现，则认为 A_m 出现概率最大。

离散型分布的最大似然估计

若总体 X 属离散型, 其分布律

$$P\{X = x\} = p(x; \theta), \theta \in \Theta$$

的形式已知, θ 为待估计参数, Θ 是 θ 的取值范围。

设 $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 则 $X_1, X_2, \dots, X_n$ 的联合分布律为

$$\prod_{i=1}^n P(X_i = x_i)$$

又设 $x_1, x_2, \dots, x_n$ 是 $X_1, X_2, \dots, X_n$ 的一个样本值, 事件 $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ 发生的概率为:

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

$L(\theta)$ 称为样本的**似然函数**

连续型分布的最大似然估计


若总体 X 属连续型, 其概率密度 $f(x; \theta), \theta \in \Theta$ 的形式已知, θ 为待估计参数, Θ 是 θ 的取值范围。

设 $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 则 $X_1, X_2, \dots, X_n$ 的联合概率密度为

$$\prod_{i=1}^n f(x_i; \theta)$$

又设 $x_1, x_2, \dots, x_n$ 是 $X_1, X_2, \dots, X_n$ 的一个样本值, 则随机点 $(X_1, X_2, \dots, X_n)$ 落在 $(x_1, x_2, \dots, x_n)$ 的邻域(dx_i 为边长的 n 维立方体)内的概率近似为:

$$\prod_{i=1}^n f(x_i; \theta) dx_i$$



连续型分布的最大似然估计

选取得到观察值 $(x_1, x_2, \dots, x_n)$ 最大化上式情况下的 θ 作为其估计值 $\hat{\theta}$

注意到, $\prod_{i=1}^n dx_i$ 不随 θ 改变, 故只需考虑

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

$L(\theta)$ 同样称为样本的似然函数

最大似然估计原理:

固定 $x_1, x_2, \dots, x_n$, 选择使概率 $L(x_1, x_2, \dots, x_n; \theta)$ 达到最大的参数 $\hat{\theta}$ 作为对 θ 的估计值, 即取 $\hat{\theta}$ 使得:

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

$\hat{\theta}$ 与 $x_1, x_2, \dots, x_n$ 有关, 记为 $\hat{\theta}(x_1, x_2, \dots, x_n)$, 称其为参数 θ 的最大似然估计值。

这种求未知参数 θ 的方法称为最大似然法

若 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$

则称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的最大似然估计值

称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的最大似然估计量

一般情况下 $p(x_i; \theta)$, $f(x_i; \theta)$ 关于 θ 可导, 故 θ 可由下式求得:

$$\frac{dL(\theta)}{d\theta} = 0 \quad \text{—— 似然方程}$$

又因为 $L(\theta)$ 与 $\ln L(\theta)$ 在同一 θ 处取得极值, 因此有等价的对数似然方程

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

样本 $X_1, X_2, \dots, X_n$ 的联合密度函数与似然函数的异同

相同点——形式上一致，都是

$$\prod_{i=1}^n f(x_i; \theta)$$

不同点——

在联合密度函数中 θ 看作是固定数

在似然函数中将 θ 看作是变量

从单一参数到多参数

若总体的分布中包含多个参数，则可令

$$\frac{dL}{d\theta_i} = 0, \quad i = 1, 2, \dots, k$$

或

$$\frac{d\ln L}{d\theta_i} = 0, \quad i = 1, 2, \dots, k$$

解 k 个方程组求得 $\theta_1, \theta_2, \dots, \theta_k$ 的最大似然估计值

一般而言，最大似然估计优于矩估计

注意：若似然方程（组）无解，或似然函数不可导，此法失效，改用其它方法

例6. 设 $X \sim B(1, p)$, $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 试求参数 p 的MLE。

解: 设 $x_1, x_2, \dots, x_n$ 是一个样本值, X 的分布律为:

$$P\{X = x\} = p^x(1 - p)^{1-x}, x = 0, 1$$

故似然函数为:

$$L(p) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$

而

$$\ln L(p) = \ln p \sum_{i=1}^n x_i + \ln(1 - p) \left(n - \sum_{i=1}^n x_i \right)$$

令

$$\frac{d\ln L(p)}{dp} = 0$$

得到

$$\frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0$$

解得 p 的MLE值为

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

p 的MLE量为

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

注意：与矩估计量是相同的

例7. 设总体 $X \sim N(\mu, \sigma^2)$, 但 μ 、 σ^2 未知,
 $x_1, x_2, \dots, x_n$ 是一个样本。求 μ 、 σ^2 的最大似然估计量

解: X 的概率密度为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$

于是似然函数为:

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\}$$

$$= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}}$$

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}$$

$$\text{令} \begin{cases} \frac{d}{d\mu} \ln L(\mu, \sigma^2) = 0 \\ \frac{d}{d\sigma^2} \ln L(\mu, \sigma^2) = 0 \end{cases}'$$

$$\ln L = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}$$

$$\text{得} \begin{cases} \frac{\sum_{i=1}^n x_i - n\mu}{\sigma^2} = 0 \\ -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} = 0 \end{cases}$$

$$\text{解得} \begin{cases} \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases}$$

$$\text{相应的最大似然估计量为} \begin{cases} \hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \end{cases}$$

与相应的矩估计量是相同的

例8. 设总体 X 服从参数为 $\lambda(>0)$ 的泊松分布,
 $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 试求参数 λ 的最大似然估计量。

解: X 的分布律为

$$P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda}, \quad (x = 0, 1, \dots, n)$$

于是 λ 的似然函数为

$$L(\lambda) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}$$

$$\ln L(\lambda) = -n\lambda + \ln \lambda \sum_{i=1}^n x_i - \sum_{i=1}^n \ln x_i$$

令

$$\frac{d}{d\lambda} \ln L(\lambda) = -n + \frac{\sum_{i=1}^n x_i}{\lambda} = 0$$

解得 λ 的MLE值为

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

λ 的最大似然估计量为

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

与相应的矩估计量是相同的

例9. 设总体 X 的密度函数为

$$f(x) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1 \\ 0, & otherwise \end{cases}$$

其中 θ 未知, $\theta > 1$, $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 试求参数 θ 的最大似然估计

解: 似然函数为: $L(\theta) = \theta^n (\prod_{i=1}^n x_i)^{\theta-1}$

于是, $\ln L(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i$

令 $\frac{d}{d\theta} \ln L = 0$, 有似然方程 $\frac{n}{\theta} + \sum_{i=1}^n \ln x_i = 0$

解得 $\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln x_i}$,

因此 θ 的最大似然估计量为 $\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln X_i}$

例10. 设总体 $X \sim U[a, b]$, a, b 未知, $X_1, X_2, \dots, X_n$ 是一个样本, 求 a, b 的最大似然估计量。

注意: X 的概率密度为 $f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & otherwise \end{cases}$

似然函数为

$$L(a, b) = \frac{1}{(b-a)^n}$$

$$\ln L(a, b) = -n \ln(b-a)$$

于是 $\frac{\partial \ln L}{\partial a} = \frac{n}{b-a} = 0, \frac{\partial \ln L}{\partial b} = -\frac{n}{b-a} = 0,$

显然, 似然方程组无解, 但这不能说明不存在最大似然估计量, 只是不能由似然方程组求解。

解：将 $x_1, x_2, \dots, x_n$ 排序 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

则

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)} \leq \dots \leq x_{(n)} \leq b \\ 0, & otherwise \end{cases}$$

对于满足 $a \leq x_{(1)} \leq \dots \leq x_{(n)} \leq b$ 的任意 a, b 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n}$$

即 $L(a, b)$ 在 $b = x_{(n)}, a = x_{(1)}$ 时, 取最大值

MLE值为: $\hat{b} = x_{(n)} = \max x_i, \hat{a} = x_{(1)} = \min x_i$

MLE量为: $\hat{b} = \max X_i, \hat{a} = \min X_i$

例11 为了估计湖中有多少条鱼，从湖中捞出1000条鱼，标上记号后又放回湖中，过一段时间后，再捞出150条鱼，发现其中有10条鱼带有标记，估计湖中鱼的总数为多少时使上述事件的概率为最大？

解： 设湖中鱼的总数为 N ，则带记号的鱼所占比例为 $1000/N$ ．令 X 为从湖中捞起一条鱼所带有的记号数．则

$$X \sim B(1, p)$$
$$P\{X = x\} = \begin{cases} \frac{1000}{N}, & x = 1 \\ 1 - \frac{1000}{N}, & x = 0 \end{cases}$$

设 $X_i = \begin{cases} 1, & \text{第} i \text{条鱼有标记} \\ 0, & \text{否则} \end{cases}, \quad i = 1, 2, \dots, 150$

由于湖中鱼的数量众多，第二次捞鱼可近似为有放回抽样

于是令

$$Y = \sum_{i=1}^{150} X_i$$

则 $Y = \sum_{i=1}^{150} X_i \sim B\left(150, \frac{1000}{N}\right)$

则题中的事件为 $\{Y = 10\}$ ，取似然函数为：

$$L(N) = P\{Y = 10\} = C_{150}^{10} \left(\frac{1000}{N}\right)^{10} \left(\frac{N - 1000}{N}\right)^{140}$$

$$L(N) = C_{150}^{10} \frac{1000^{10} (N - 1000)^{140}}{N^{150}}$$

于是,

$$\ln L(N) = \ln C_{150}^{10} + 10 \ln 1000 + 140 \ln(N - 1000) - 150 \ln N$$

令,

$$\frac{d}{dN} \ln L(N) = \frac{140}{N - 1000} - \frac{150}{N} = 0$$

解得 $N = 15000$

即当湖中的鱼数为15000条时, 概率 $P\{Y = 10\}$ 为最大。

最大似然估计量的不变性

设 θ 的**函数** $u = u(\theta)$, $\theta \in \Theta$ 具有**单值反函数**, $\hat{\theta}$ 是 θ 的最大似然估计, 则

$\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ **的最大似然估计**。

例: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 σ^2 的最大似然估计,

$u = u(\sigma^2) = \sqrt{\sigma^2}$ 有单值反函数 $\sigma^2 = u^2, (u \geq 0)$

故 $\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$ 是 σ 的最大似然估计

例12. 设 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知, 求使 $P\{X > A\} = 0.05$ 的点 A 的最大似然估计量。

解:

$$P\{X > A\} = 1 - \Phi\left(\frac{A - \mu}{\sigma}\right) = 0.05$$

查表有 $\frac{A - \mu}{\sigma} = 1.645$, 故有 $A = \mu + 1.645\sigma$

由前面知 μ, σ^2 的最大似然估计量分别为:

$$\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

故 A 的最大似然估计量为

$$\hat{A} = \hat{\mu} + 1.645\hat{\sigma} = \bar{X} + 1.645 \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

§2 估计量的评选标准

缘起：对于同一个参数, 用不同的估计方法求出的估计量可能不相同。而且, 很明显, 原则上任何统计量都可以作为未知参数的估计量

问题

- (1) 对于同一个参数究竟采用哪一个估计量好?
- (2) 评价估计量的标准是什么?

考虑估计的性质

- (1) 无偏性
- (2) 有效性
- (3) 相合性(一致性)

一、无偏性

若 $X_1, X_2, \dots, X_n$ 为总体 X 的一个样本, $\theta \in \Theta$ 是包含在总体 X 的分布中的待估计参数,

若估计量 $\hat{\theta} = \theta(X_1, X_2, \dots, X_n)$ 的数学期望 $E(\hat{\theta})$ 存在且对于任意 $\theta \in \Theta$ 有 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 为 θ 的无偏估计量

无偏估计意味着无系统性误差

例13. 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ ($k \geq 1$)存在, 又设 $X_1, X_2, \dots, X_n$ 为总体 X 的一个样本, 试证明不论总体服从何种分布, k 阶样本矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 k 阶总体矩 μ_k 的无偏估计。

证明: 因为 $X_1, X_2, \dots, X_n$ 与 X 同分布, 故有

$$E(X_i^k) = E(X^k) = \mu_k$$

即

$$E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k$$

故 k 阶样本矩 A_k 是 k 阶总体矩 μ_k 的无偏估计

注意: 不论总体 X 服从什么分布, 只要它的数学期望存在, $\bar{X}$ 总是总体 X 的数学期望 $\mu_1 = E(X)$ 的无偏估计

例14. 对于均值 μ , 方差 σ^2 都存在的总体, 若 μ 和 σ^2 均为未知, 则 σ^2 的估计量 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是有偏的。

证明: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = A_2 - \bar{X}^2$

因为 $E(A_2) = \mu_2 = \sigma^2 + \mu^2$

而 $E(\bar{X}^2) = D(\bar{X}) + [E(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2$

于是有

$$\begin{aligned} E(\hat{\sigma}^2) &= E(A_2 - \bar{X}^2) = E(A_2) - E(\bar{X}^2) \\ &= \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2 = \frac{n-1}{n} \sigma^2 \neq \sigma^2 \end{aligned}$$

故是有偏的。

若以 $\frac{n}{n-1}$ 乘以 $\hat{\sigma}^2$, 所得到的估计量就是无偏的(这种方法称为无偏化)

$$E\left(\frac{n}{n-1}\hat{\sigma}^2\right) = \frac{n}{n-1}E(\hat{\sigma}^2) = \sigma^2$$

因为

$$\frac{n}{n-1}\hat{\sigma}^2 = S^2 = \frac{1}{n-1}\sum_{i=1}^n (X_i - \bar{X})^2$$

即 S^2 是 σ^2 的无偏估计, 通常取 S^2 作为 σ^2 的估计量

例16. 设 $X \sim N(\mu, \sigma^2)$, μ 已知, σ^2 未知, $x_1, x_2, \dots, x_n$ 是来自 X 的一个样本值, 求 σ^2 的最大似然估计量。

解: X 的概率密度函数为:

$$f(x; \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$

似然函数为:

$$\begin{aligned} L(\sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \right\} \\ \ln L &= -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

$$\ln L = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}$$

令

$$\frac{d}{d\sigma^2} \ln L = -\frac{n}{2\sigma^2} - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} = 0$$

解得：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

注意到

$$\begin{aligned} E(\hat{\sigma}^2) &= E\left(\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2\right) \\ &= \frac{1}{n} \sum_{i=1}^n E[(x_i - \mu)^2] = \frac{1}{n} \times n\sigma^2 = \sigma^2 \end{aligned}$$

故, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$ 是总体方差的无偏估计

例17. 设总体 X 服从参数为 θ 的指数分布, 概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & otherwise \end{cases}$$

参数 $\theta > 0$, 又设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 试证 $\bar{X}$ 和 $nZ = n[\min(X_1, X_2, \dots, X_n)]$ 都是 θ 的无偏估计。

证明: 因为 $E(\bar{X}) = E(X) = \theta$,
所以 $\bar{X}$ 是 θ 的无偏估计量。

而 $Z = \min(X_1, X_2, \dots, X_n)$ 服从参数为 $\frac{\theta}{n}$ 的指数分布,

$$f_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0 \\ 0, & otherwise \end{cases}$$

故知 $E(Z) = \frac{\theta}{n}$, $E(nZ) = \theta$,

所以 nZ 也是 θ 的无偏估计量。

由此可知, 一个参数可以有不同的无偏估计量

注意: 如果未知参数 θ 有两个不同的无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$, 则一定有无穷多个无偏估计

$$\alpha \hat{\theta}_1 + (1 - \alpha) \hat{\theta}_2$$

二、有效性

比较参数 θ 的两个无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ ，如果在样本容量 n 相同的情况下， $\hat{\theta}_1$ 的观察值在真值 θ 的附近较 $\hat{\theta}_2$ 更为密集，则认为 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效

由于方差是随机变量取值与其数学期望的偏离程度，所以无偏估计以**方差小**者为好

形式化：

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计量，若有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$ ，则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效

例18. 设总体 X 服从参数为 θ 的指数分布, 概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & otherwise \end{cases}$$

参数 $\theta > 0$, 又设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 试证 θ 的无偏估计中, 当 $n > 1$ 时 $\bar{X}$ 较 nZ 更为有效。

证明: 由于 $D(X) = \theta^2$, 故有 $D(\bar{X}) = \frac{\theta^2}{n}$

又因为 $D(Z) = \frac{\theta^2}{n^2}$, 故有 $D(nZ) = \theta^2$

当 $n > 1$ 时, $D(nZ) > D(\bar{X})$,

所以 θ 的无偏估计中, 当 $n > 1$ 时 $\bar{X}$ 较 nZ 更为有效

三、相合性(一致性)

若 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为参数 θ 的估计量, 如果对于任意 $\theta \in \Theta$, 当 $n \rightarrow \infty$ 时 $\hat{\theta} \xrightarrow{P} \theta$, 则称 $\hat{\theta}$ 是 θ 的**一致估计**。

例19. 若 $X_1, X_2, \dots, X_n$ 是总体 X 的样本, $E[X] = \mu$, $E[X^k] = \mu_k$, 有辛钦大数定理, 知对任意给定的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| \geq \epsilon \right\} = 0$$

因此, 样本均值 $\bar{X}$ 是总体期望 μ 的相合(一致)估计量; 更一般地, 样本的 k 阶矩是总体 k 阶矩的相合(一致)估计量。

作业

概率论与数理统计

pp. 176-178, #2, #5, #10, #12