

第四章 随机变量的数字特征 习题课

期中考试：2025年11月25日

目录

- ❑ 第四章知识点回顾
- ❑ 第四章典型例题
- ❑ Excel 实验
- ❑ 扩展内容：主成分分析

- 第四章：随机变量的数字特征 } 描述随机变量分布的特征
 - § 1 数学期望 } 描述单个随机变量
 - § 2 方差 } (如 $X, Y, Z = X + Y, Z = XY$ 等) 分布的特征
 - § 3 协方差及相关系数 } 描述变量之间的相关程度
 - § 4 矩、协方差矩阵 }

主要内容

一. 数学期望

定义

离散型

连续型

随机变量
函数的数
学期望

二. 方差

定义

计算

性质

切比雪夫不等式

四. n维随机变量的 期望、协方差、相关系数

三. 协方差 & 相关系数 & 矩

定义

协方差的性质

相关系数定理

数学期望

□ 设**离散型**随机变量 X 的分布律为

$$P\{X = x_k\} = p_k, k = 1, 2, \dots$$

$$\sum_{k=1}^{\infty} |x_k| p_k < +\infty$$

若级数 $\sum_{k=1}^{\infty} x_k p_k$ **绝对收敛**，则称 $\sum_{k=1}^{\infty} x_k p_k$ 为**离散型**随机变量 X 的**数学期望**。记为 $E(X)$ ，即

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

□ 设**连续型**随机变量 X 的概率密度为 $f(x)$ ，若积分 $\int_{-\infty}^{+\infty} x f(x) dx$ **绝对收敛**，则称此积分值为**连续型**随机变量 X 的**数学期望**。记为 $E(X)$ ，即

$$\int_{-\infty}^{+\infty} |x| f(x) dx < +\infty$$

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

随机变量函数的数学期望

□ 离散型随机变量函数

若 $Y = g(X)$, 且 $P\{X = x_k\} = p_k$, $k = 1, 2, \dots$, 且 $\sum_{k=1}^{\infty} g(x_k)p_k$ 绝对收敛, 则 Y 的数学期望为

$$E(g(X)) = \sum_{k=1}^{\infty} g(x_k)p_k$$

□ 连续型随机变量函数

连续型随机变量 X 的概率密度为 $f(x)$, 若 $Y = g(X)$, 且 $\int_{-\infty}^{+\infty} g(x)f(x)dx$ 绝对收敛, 则 Y 的数学期望为

$$E(g(X)) = \int_{-\infty}^{+\infty} g(x)f(x)dx$$

数学期望的性质

1. 设 C 是常数, 则有 $E(C) = C$.

2. 设 X 是一个随机变量, C 是常数, 则有

$$E(CX) = CE(X).$$

3. 设 X, Y 是两个随机变量, 则有

$$E(X + Y) = E(X) + E(Y).$$

期望: 加法不需要独立性

$$E(aX + bY + c) = aE(X) + bE(Y) + c$$

4. 设 X, Y 是相互独立的随机变量, 则有

$$E(XY) = E(X)E(Y).$$

期望: 乘法需要独立性

二维随机变量的数学期望

□ 设 (X, Y) 为二维随机变量, 若 $E(X), E(Y)$ 都存在, 则 X 与 Y 的期望分别定义为

$$E(X) = \begin{cases} \sum_i \sum_j x_i p_{ij} & \text{离散型} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f(x, y) dx dy & \text{连续型} \end{cases}$$

(X, Y) 的概率分布律为 p_{ij}
(X, Y) 的概率密度为 $f(x, y)$

$$E(Y) = \begin{cases} \sum_i \sum_j y_i p_{ij} & \text{离散型} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y f(x, y) dx dy & \text{连续型} \end{cases}$$

(X, Y) 的概率分布律为 p_{ij}
(X, Y) 的概率密度为 $f(x, y)$

↑ 利用联合分布求单个变量的期望

二维随机变量函数的数学期望

□ 若 X, Y 为**离散型**随机变量, $g(x, y)$ 是二元函数, (X, Y) 的联合概率分布律为 p_{ij} , 且 **$E[g(X, Y)]$ 存在**, 则

$$E[g(X, Y)] = \sum_i \sum_j g(x_i, y_j) p_{ij}$$

□ 若 X, Y 为**连续型**随机变量, $g(x, y)$ 是二元函数, (X, Y) 的联合分布密度为 $f(x, y)$, 且 **$E[g(X, Y)]$ 存在**, 则

$$E[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$$

方差

□ **定义**: 设 X 是一个随机变量, 若 $E\{[X - E(X)]^2\}$ 存在, 则称 $E\{[X - E(X)]^2\}$ 是 X 的**方差**, 记作 $D(X)$ 或 $Var(X)$, 即

$$D(X) = Var(X) = E\{[X - E(X)]^2\}$$

方差的
非负性

□ 称 $\sqrt{D(X)}$ 为**标准差**或**均方差**, 记作 $\sigma(X)$ 。

□ 方差的计算

▪ 离散型随机变量 $D(X) = \sum_{k=1}^{\infty} [x_k - E(X)]^2 p_k$

▪ 连续型随机变量 $D(X) = \int_{-\infty}^{+\infty} [x_k - E(X)]^2 f(x) dx$

▪ 常用计算公式 $D(X) = E\{[X - E(X)]^2\} = E(X^2) - [E(X)]^2$

方差的性质

1. 设 C 是常数, 则有 $D(C) = 0$.

2. 设 X 是一个随机变量, C 是常数, 则有

$$D(CX) = C^2 D(X).$$

3. 设 X, Y **相互独立**, $D(X), D(Y)$ 存在, 则有

$$D(X \pm Y) = D(X) + D(Y). \quad \text{方差: 加法需要独立性}$$

否则, $D(X \pm Y) = D(X) + D(Y) \pm 2(E(XY) - E(X)E(Y))$

4. $D(X) = 0$ 的**充要条件**是 X 以概率1取常数 C , 即

$$D(X) = 0 \iff P(X = C) = 1$$


期望: 可**加**性**不要求**独立、可**乘**性要求**独立**
 方差: 可**加**性要求**独立**

切比雪夫(Chebyshev)不等式


□ 设随机变量 X 数学期望 $E(X) = \mu$ **存在**, 方差 $D(X) = \sigma^2$, 则对于 **任意正数** ϵ , 则有

$$P\{|X - \mu| \geq \epsilon\} \leq \frac{\sigma^2}{\epsilon^2} \Leftrightarrow P\{|X - \mu| < \epsilon\} \geq 1 - \frac{\sigma^2}{\epsilon^2}$$

$$\begin{aligned} P\{|X - \mu| \geq \epsilon\} &= \int_{|x - \mu| \geq \epsilon} f(x) dx \\ &\leq \int_{|x - \mu| \geq \epsilon} \frac{|x - \mu|^2}{\epsilon^2} f(x) dx \leq \frac{\sigma^2}{\epsilon^2} \end{aligned}$$




切比雪夫不等式的几何直观解释



$$I(|x-a| \geq b) \leq \frac{(x-a)^2}{b^2}$$

$$I(|X-\mu| \geq \epsilon) \leq \frac{(X-\mu)^2}{\epsilon^2}$$




$$P(|X-\mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}$$

两边求期望

回顾：正态分布&3 σ 准则

□ 若随机变量 X 的密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (-\infty < x < +\infty)$$



则称随机变量 X 服从参数为 (μ, σ^2) 的**正态分布**，记作
 $X \sim N(\mu, \sigma^2)$

$$P\{|X - \mu| < \epsilon\} \geq 1 - \frac{\sigma^2}{\epsilon^2}$$

□ 当 $X \sim N(0,1)$ 时，

切比雪夫界

$$P(|X| \leq 1) = 2\Phi(1) - 1 = 0.6826 \quad 0$$

$$P(|X| \leq 2) = 2\Phi(2) - 1 = 0.9544 \quad 0.75$$

$$P(|X| \leq 3) = 2\Phi(3) - 1 = 0.9974 \quad 0.89$$

X 的取值集中在 $[-3, 3]$ 区间内，超出这个范围的可能不到0.3%.

协方差与相关系数

□ 随机变量 X 与 Y 的**协方差**

$$\mathbf{Cov}(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$$

□ 协方差常用计算方法

$$\mathbf{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

□ 随机变量 X 与 Y 的**相关系数**

$$\rho_{XY} = \frac{\mathbf{Cov}(X, Y)}{\sqrt{D(X)} \cdot \sqrt{D(Y)}}$$

协方差性质

$$1. \text{Cov}(X, Y) = \text{Cov}(Y, X).$$

$$2. \text{Cov}(aX, bY) = ab\text{Cov}(X, Y) \quad (a, b \text{ 为常数})$$

$$3. \text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y).$$

$$\text{Cov}(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$$

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

$$D(X \pm Y) = D(X) + D(Y) \pm 2\text{Cov}(X, Y)$$

按方差定义展开即得

相关系数性质

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \cdot \sqrt{D(Y)}}$$

1) $|\rho_{XY}| \leq 1$

2) $|\rho_{XY}| = 1$ 的充要条件是：存在常数 a 、 b ，使得

$$P\{Y = a + bX\} = 1$$

Y 可被 X 线性表出

□ **相关系数**只能说明两个变量之间是否存在**线性关系**，不能得出两个变量是否独立。

独立 $\Rightarrow$ 不相关； 不相关 $\nRightarrow$ 独立

X 、 Y 相互独立时， $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0$

■ 特例：若 X 、 Y 都是正态分布，则独立与不相关等价。

常见分布的数学期望与方差

分 布	参 数	数学期望	方差
两点分布	$0 < p < 1$	p	$p(1 - p)$
二项分布	$n \geq 1,$ $0 < p < 1$	np	$np(1 - p)$
泊松分布	$\lambda > 0$	λ	λ
均匀分布	$a < b$	$(a + b)/2$	$(b - a)^2 / 12$
指数分布	$\theta > 0$	θ	θ^2
正态分布	$\mu, \sigma > 0$	μ	σ^2

求离散型随机变量的期望与方差

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

$$D(X) = E(X^2) - E^2(X) = \sum_{k=1}^{\infty} x_k^2 p_k - \left(\sum_{k=1}^{\infty} x_k p_k \right)^2$$

涉及的计算技巧：特殊序列求和

$$\sum_{k=1}^n k = \frac{n(n+1)}{2}, \quad \sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}, \quad e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$$

令 $X_1, X_2, \dots, X_n$ 为相互独立的随机变量, 每一个都具有均匀分布

$P\{X_i = k\} = \frac{1}{N}, k = 1, 2, \dots, N$ 。令 U_n 和 V_n 分别表示 $X_1, X_2, \dots, X_n$ 中的最小值和最大值。求出 U_n 和 V_n 的分布。

解: $V_n = \max\{X_1, X_2, \dots, X_n\}$

$$P\{V_n = k\} = P\{V_n \leq k\} - P\{V_n \leq k - 1\}$$

$$P\{V_n \leq k\} = P\{X_1 \leq k, X_2 \leq k, \dots, X_n \leq k\}$$

$$= P\{X_1 \leq k\}P\{X_2 \leq k\} \cdots P\{X_n \leq k\}$$

$$= \left(\sum_{j=1}^k P\{X_i = j\} \right)^n = \left(\frac{k}{N} \right)^n$$

$$P\{V_n = k\} = P\{V_n \leq k\} - P\{V_n \leq k - 1\} = \left(\frac{k}{N} \right)^n - \left(\frac{k - 1}{N} \right)^n$$

$$E(V_n) \approx \frac{n}{n+1} N \quad \text{详见《概率论及其应用》 9.3(3.6)(3.7)}$$

令 $X_1, X_2, \dots, X_n$ 为相互独立的随机变量, 每一个都具有均匀分布

$P\{X_i = k\} = \frac{1}{N}, k = 1, 2, \dots, N$ 。令 U_n 和 V_n 分别表示 $X_1, X_2, \dots, X_n$ 中的最小值和最大值。求出 U_n 和 V_n 的分布。

解: $U_n = \min\{X_1, X_2, \dots, X_n\}$

$$P\{U_n = k\} = P\{U_n \leq k\} - P\{U_n \leq k-1\}$$

$$\begin{aligned} P\{U_n \leq k\} &= 1 - P\{U_n > k\} \\ &= 1 - P\{X_1 > k, X_2 > k, \dots, X_n > k\} \\ &= 1 - P\{X_1 > k\}P\{X_2 > k\} \cdots P\{X_n > k\} \\ &= 1 - \left(\sum_{j=k+1}^N P\{X_i = j\}\right)^n = 1 - \left(\frac{N-k}{N}\right)^n, \end{aligned}$$

$$\begin{aligned} P\{U_n = k\} &= P\{U_n \leq k\} - P\{U_n \leq k-1\} \\ &= 1 - \left(\frac{N-k}{N}\right)^n - 1 + \left(\frac{N-k+1}{N}\right)^n = \left(\frac{N-k+1}{N}\right)^n - \left(\frac{N-k}{N}\right)^n \end{aligned}$$

$$E(U_n) \approx \frac{1}{n+1}N$$

有一个人想开门。他共有 n 把钥匙，他试开门时所抽取的钥匙是相互独立且随机的。求试验次数的均值与方差。(a) 如果以前选出来的不能开门的钥匙不除去。(b) 如果以前选无效钥匙除去。

解(a): 设 X 表示试验次数，在情况(a)时， X 服从几何分布，它的分布律为 $P\{X = k\} = (1 - p)^{k-1}p$, $p = \frac{1}{n}, k = 1, 2, \dots$,

$$E(X) = \sum_{k=1}^{\infty} kq^{k-1}p \quad \text{其中 } q = 1 - p, p = \frac{1}{n}$$

$$= p \sum_{k=1}^{\infty} kq^{k-1} = \frac{p}{(1 - q)^2} = \frac{1}{p} = n$$

求和项计算：乘以 q 相减

$$\text{令 } S = \sum_{k=1}^{\infty} kq^{k-1} = 1 + 2q + 3q^2 + 4q^3 + \dots$$

$$qS = q + 2q^2 + 3q^3 + \dots$$

$$\text{两式相减: } (1 - q)S = 1 + q + q^2 + q^3 + \dots = \frac{1}{1 - q} \Rightarrow S = \frac{1}{(1 - q)^2}$$

有一个人想开门。他共有 n 把钥匙，他试开门时所抽取的钥匙是相互独立且随机的。求试验次数的均值与方差。（a）如果以前选出来的不能开门的钥匙不除去。（b）如果以前选的无效钥匙除去。

解(a): 设 X 表示试验次数，在情况（a）时， X 服从几何分布，它的分布律为 $P\{X = k\} = (1 - p)^{k-1}p$, $p = \frac{1}{n}, k = 1, 2, \dots$,

$$E(X) = \frac{1}{p} = n \quad \text{其中 } q = 1 - p, p = \frac{1}{n}$$

$$E(X^2) = \sum_{k=1}^{\infty} k^2 q^{k-1} p = p \sum_{k=1}^{\infty} k^2 q^{k-1} = \frac{p(1+q)}{p^3} = \frac{1+q}{p^2}$$

$$D(X) = E(X^2) - [E(X)]^2 = \frac{1+q}{p^2} - \frac{1}{p^2} = \frac{q}{p^2} = n(n-1)$$

解(a)附:

$$E(X^2) = \sum_{k=1}^{\infty} k^2 q^{k-1} p = p \sum_{k=1}^{\infty} k^2 q^{k-1} = \frac{p(1+q)}{p^3} = \frac{1+q}{p^2}$$

$$S = \sum_{k=1}^{\infty} k^2 q^{k-1} = 1 + 2^2 q + 3^2 q^2 + 4^2 q^3 + \dots + k^2 q^{k-1} + \dots$$

$$qS = q + 2^2 q^2 + 3^2 q^3 + \dots + (k-1)^2 q^k + \dots$$

$$\Rightarrow (1-q)S = 1 + (2^2 - 1)q + (3^2 - 2^2)q^2 + \dots + (k^2 - (k-1)^2)q^{k-1} + \dots$$

$$= 1 + 3q + 5q^2 + \dots + (2k-1)q^{k-1} + \dots \quad (1)$$

$$\Rightarrow q \cdot (1-q)S = q + 3q^2 + 5q^3 + \dots + (2k-1)q^{k-1} + \dots \quad (2)$$

(1) - (2) 得:

$$(1-q)^2 S = 1 + 2q + 2q^2 + 2q^3 + \dots + 2q^{k-1} + \dots = 2 \left(\frac{1}{1-q} \right) - 1 = \frac{1+q}{1-q}$$

$$\Rightarrow S = \frac{1+q}{(1-q)^3}$$

有一个人想开门。他共有 n 把钥匙，他试开门时所抽取的钥匙是相互独立且随机的。求试验次数的均值与方差。（a）如果以前选出来的不能开门的钥匙不除去。（b）如果以前选无效钥匙除去。

解(b): X : 试验次数, 情况 (b) 时, X 的分布律为 $P\{X = k\} = \frac{1}{n}$

$$E(X) = \sum_{k=1}^n k \frac{1}{n} = \frac{n+1}{2}$$

$$E(X^2) = \sum_{k=1}^n \frac{k^2}{n} = \frac{1}{n} \sum_{k=1}^n k^2 = \frac{(n+1)(2n+1)}{6}$$

$$D(X) = E(X^2) - [E(X)]^2 = \frac{(n+1)(n-1)}{12}$$

令 $X_1, X_2, \dots, X_n$ 为相互独立的随机变量, 其均值为 m , 方差为 σ^2 . 令 $\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$, 证明 $\frac{1}{n-1} E(\sum_{k=1}^n (X_k - \bar{X})^2) = \sigma^2$

证:

$$\begin{aligned}
 E(\sum_{k=1}^n (X_k - \bar{X})^2) &= E(\sum_{k=1}^n [X_k^2 - 2X_k \bar{X} + \bar{X}^2]) = \\
 &= E(\sum_{k=1}^n X_k^2) - E(\sum_{k=1}^n 2X_k \bar{X}) + E(\sum_{k=1}^n \bar{X}^2) \\
 &= \sum_{k=1}^n E(X_k^2) - 2E(\bar{X} \sum_{k=1}^n X_k) + nE(\bar{X}^2) \\
 &= \sum_{k=1}^n E(X_k^2) - 2nE(\bar{X}^2) + nE(\bar{X}^2) = \sum_{k=1}^n E(X_k^2) - nE(\bar{X}^2) \\
 &= (n-1)\sigma^2
 \end{aligned}$$

$$E(X_k^2) = D(X_k) + E^2(X) = \sigma^2 + m^2$$

$$\begin{aligned}
 E(\bar{X}^2) &= E\left(\frac{\sum_{i=1}^n X_i}{n} \frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n^2} E\left(\sum_{i=1}^n X_i^2 + \sum_{i \neq j} X_i X_j\right) = \frac{nE(X_i^2)}{n^2} + \\
 &\quad \frac{n(n-1)E(X_i)E(X_j)}{n^2} = \frac{\sigma^2}{n} + m^2
 \end{aligned}$$

例1. 从数字 $0, 1, 2, \dots, n$ 中任取两个不同的数字, 求这两个数字之差的绝对值的数学期望.

解: 设 Z 为所选两个数字之差的绝对值, 则 Z 的所有可能取值为 $1, 2, 3, \dots, n$

$$P\{Z = 1\} = n/C_{n+1}^2, P\{Z = 2\} = (n-1)/C_{n+1}^2$$

一般地, $P\{Z = k\} = \frac{(n-k+1)}{C_{n+1}^2}, k = 1, 2, \dots, n.$

$$E(Z) = \sum_{k=1}^n kP\{Z = k\} = \sum_{k=1}^n k \cdot (n-k+1)/C_{n+1}^2 = \frac{n+2}{3}.$$

$$\sum_{k=1}^n k = \frac{n(n+1)}{2}, \quad \sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}$$

例2. 设随机变量 X 取非负整数值 $n \geq 0$ 的概率为 $p_n = \frac{AB^n}{n!}$, 已知 $E(X) = a$, 求 A 与 B 的值。

e^x 泰勒展开: $e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$

解:
$$\sum_{n=0}^{+\infty} P\{X = n\} = \sum_{n=0}^{+\infty} A \frac{B^n}{n!} = A e^B = 1 \Rightarrow A = e^{-B}$$

$$E(X) = \sum_{n=1}^{+\infty} n A \frac{B^n}{n!} = \sum_{n=1}^{+\infty} \frac{AB^n}{(n-1)!} = AB e^B = a$$

$$\Rightarrow A = e^{-a}, B = a$$

泰勒展开: $f(x) = \frac{f(x_0)}{0!} + \frac{f'(x_0)}{1!}(x-x_0) + \frac{f''(x_0)}{2!}(x-x_0)^2 + \dots + \frac{f^{(n)}(x_0)}{n!}(x-x_0)^n + R_n(x)$

例3. (*Laplace*配对) 将 n 只球 ($1 \sim n$ 号) 随机地放入 n 个盒子 ($1 \sim n$ 号), 若一只球装入与球同号的盒子中, 则称为一个配对。记 X 为总的配对数, 求其期望?

解: 引入随机变量 $X_i = \begin{cases} 1, & \text{第} i \text{个球放第} i \text{个盒子} \\ 0, & \text{其它} \end{cases}, i = 1, 2, \dots, n.$

则 $X = X_1 + X_2 + \dots + X_n.$

$$P\{X_i = 1\} = \frac{(n-1)!}{n!} = \frac{1}{n}, \quad P\{X_i = 0\} = 1 - \frac{1}{n}$$

由此 $E(X_i) = \frac{1}{n}, \quad i = 1, 2, \dots.$

$$\begin{aligned} E(X) &= E(X_1 + X_2 + \dots + X_n) \\ &= E(X_1) + E(X_2) + \dots + E(X_n) = n \times \frac{1}{n} = 1 \end{aligned}$$

求连续型随机变量的期望与方差

$$E(X) = \int_{-\infty}^{+\infty} \boldsymbol{x} f(x) dx$$

$$D(X) = \int_{-\infty}^{+\infty} [\boldsymbol{x}_k - \boldsymbol{E}(X)]^2 f(x) dx = E(X^2) - E^2(X)$$

计算：

1. 根据定义算积分
2. 运用随机变量数字特征之间的关系式
3. 计算过程中，熟练运用各类积分技巧

例4. 设随机变量 X 的密度函数如下, 求 $E(X)$ 和 $D(X)$ 。

$$f(x) = \begin{cases} c(1-x^2)^\alpha, & -1 < x < 1, \\ 0, & \text{其他.} \end{cases} \quad (\alpha < 0)$$

解: 因为 $f(x)$ 是偶函数, $E(X) = \int_{-\infty}^{+\infty} xf(x)dx = 0$,

$$\begin{aligned} D(X) &= E(X^2) - [E(X)]^2 = E(X^2) = \int_{-1}^1 cx^2(1-x^2)^\alpha dx \\ &= -\frac{c}{2(\alpha+1)} x(1-x^2)^{\alpha+1} \Big|_{-1}^1 + \frac{c}{2(\alpha+1)} \int_{-1}^1 (1-x^2)^{\alpha+1} dx \\ &= D(X) \end{aligned}$$

$$= \frac{1}{2(\alpha+1)} \int_{-1}^1 c(1-x^2)^\alpha dx - \frac{1}{2(\alpha+1)} \int_{-1}^1 cx^2(1-x^2)^\alpha dx$$

得 $D(X) = \frac{1}{2(\alpha+1)} - \frac{1}{2(\alpha+1)} D(X), \quad \Rightarrow \quad D(X) = \frac{1}{2\alpha+3}.$

例5. 设随机变量 X 的概率密度 $f(x) = \frac{1}{\pi(1+x^2)}$, 求
 $E[\min(|X|, 1)]$

解

$$\begin{aligned}
 E[\min(|X|, 1)] &= \int_{-\infty}^{+\infty} \min(|x|, 1) f(x) dx \\
 &= \int_{|x| < 1} |x| f(x) dx + \int_{|x| \geq 1} f(x) dx \\
 &= \frac{1}{\pi} \int_{-1}^1 \frac{|x|}{1+x^2} dx + \frac{1}{\pi} \int_{|x| \geq 1} \frac{1}{1+x^2} dx \\
 &= \frac{2}{\pi} \int_0^1 \frac{x}{1+x^2} dx + \frac{2}{\pi} \int_1^{+\infty} \frac{1}{1+x^2} dx = \frac{1}{\pi} \ln 2 + \frac{1}{2}.
 \end{aligned}$$

$$\int \frac{1}{1+x^2} dx = \arctan x + C$$

求二维随机变量的数字特征

例6. 设二维连续型随机变量 (X, Y) 的联合密度函数为

$$f(x, y) = \begin{cases} \frac{6}{7} \left(x^2 + \frac{1}{2} xy \right), & 0 < x < 1, 0 < y < 2 \\ 0, & \text{其它} \end{cases}$$

求 (X, Y) 的协方差矩阵及相关系数。

思路： 协方差矩阵 $\Sigma = \begin{bmatrix} D(X) & \text{Cov}(X, Y) \\ \text{Cov}(Y, X) & D(Y) \end{bmatrix}$

$$\text{相关系数 } \rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \cdot \sqrt{D(Y)}}$$

$$\text{概率密度 } f(x, y) = \begin{cases} \frac{6}{7} \left(x^2 + \frac{1}{2} xy \right), & 0 < x < 1, 0 < y < 2 \\ 0, & \text{其它} \end{cases}$$

$$\begin{aligned} \text{解: } E(X) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f(x, y) dx dy = \int_0^1 \int_0^2 \frac{6}{7} x \left(x^2 + \frac{1}{2} xy \right) dy dx \\ &= \int_0^1 \left(\frac{12}{7} x^3 + \frac{6}{7} x^2 \right) dx = \frac{5}{7}, \end{aligned}$$

$$E(X^2) = \int_0^1 \int_0^2 \frac{6}{7} x^2 \left(x^2 + \frac{1}{2} xy \right) dx dy = \frac{39}{70},$$

$$\text{则 } D(X) = E(X^2) - E^2(X) = \frac{39}{70} - \left(\frac{5}{7} \right)^2 = \frac{23}{490}$$

$$E(Y) = \int_0^1 \int_0^2 \frac{6}{7} y \left(x^2 + \frac{1}{2} xy \right) dy dx = \frac{8}{7},$$

$$E(Y^2) = \int_0^1 \int_0^2 \frac{6}{7} y^2 \left(x^2 + \frac{1}{2} xy \right) dy dx = \frac{34}{21},$$

$$\text{则 } D(Y) = E(Y^2) - E^2(Y) = \frac{34}{21} - \left(\frac{8}{7} \right)^2 = \frac{46}{147}$$

$$\text{概率密度 } f(x, y) = \begin{cases} \frac{6}{7} \left(x^2 + \frac{1}{2} xy \right), & 0 < x < 1, 0 < y < 2 \\ 0, & \text{其它} \end{cases}$$

解(续): $E(XY) = \int_0^1 \int_0^2 \frac{6}{7} xy \left(x^2 + \frac{1}{2} xy \right) dy dx = \frac{17}{21},$

则 $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = \frac{17}{21} - \frac{5}{7} \times \frac{8}{7} = -\frac{1}{147},$

因此, (X, Y) 的协方差矩阵

$$\Sigma = \begin{bmatrix} D(X) & \text{Cov}(X, Y) \\ \text{Cov}(Y, X) & D(Y) \end{bmatrix} = \begin{pmatrix} \frac{23}{490} & -\frac{1}{147} \\ -\frac{1}{147} & \frac{46}{147} \end{pmatrix}.$$

X 与 Y 的相关系数 $\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}} = -\frac{\sqrt{15}}{69}.$

利用切比雪夫不等式估算概率

例7. 在供暖的季节，住房的平均温度为20度，标准差为2度，试用切比雪夫不等式估计住房温度与平均温度的偏差的绝对值小于4度的概率最少是多少？

$$P\{|X - \mu| \geq \epsilon\} \leq \frac{\sigma^2}{\epsilon^2}$$

解： 设住房的温度是随机变量 X ，其期望为 $\mu = 20$ ，方差为 $\sigma^2 = 4$ ，根据切比雪夫不等式，令 $\epsilon = 4$ ，有

$$P(|X - 20| \geq 4) \leq \frac{2^2}{4^2} = \frac{1}{4}$$


$$P(|X - 20| < 4) = 1 - P(|X - 20| \geq 4) \geq \frac{3}{4}$$

所以，住房温度与平均温度的偏差的绝对值小于4度的概率最少是75%。


Excel实验

- 概率分布函数
- 协方差和相关系数
- 数据分析工具箱

Excel界面



Excel界面



概率分布函数

□ 概率分布函数：Excel的统计函数中，命名形式如“XXDIST”或“XXX.DIST”。

- 正态分布函数

NORM.DIST(x, mean, standard_dev, cumulative)

输入：

x 必需。 需要计算其正态分布的数值。

Mean 必需。 正态分布的算术平均值。

standard_dev 必需。 正态分布的标准偏差。

Cumulative 必需。 决定函数形式的逻辑值。

如果为 **TRUE**，则返回**累积分布函数**；

如果为 **FALSE**，则返回**概率密度函数**。

实验1. 设 $X \sim N(108, 9)$, 求 $P\{102 < X < 117\}$ 。

实验过程:

	A	B
1	设 $X \sim N(108, 9)$	
2	$P(X < 102) =$	0.02275
3	$P(X < 117) =$	0.99865
4	$P(102 < X < 117) =$	0.9759

1. 在B2计算 $P(X < 102)$:

$=\text{NORM.DIST}(102, 108, 3, \text{TRUE})$

2. 在B3计算 $P(X < 117)$:

$=\text{NORM.DIST}(117, 108, 3, \text{TRUE})$

3. 在B4计算 $P(102 < X < 117)$:

$=B3 - B2$

实验2. 用Excel验证二项分布与泊松分布之间的关系。

泊松定理: 在 n 重伯努利试验中, 事件A在每次试验中发生的概率为 p , 出现A的总次数 K 服从二项分布 $B(n, p)$, 当 n 很大 p 很小, $\lambda = np$ 大小适中时, 二项分布可用参数为 $\lambda = np$ 的泊松分布来近似。

实验准备:

返回一元二项分布的概率

BINORM.DIST(**number_s**, **trials**, **probability_s**, **cumulative**)

↓
试验成功
的次数

↓
独立试验
的次数 n

↓
每次试验成功
的概率 p

↓
False: 概率密度函数
True: 累积分布函数

返回泊松分布的概率

POISSON.DIST(**x**, **mean**, **cumulative**)

↓
事件数

↓
均值
 λ

↓
False: 概率密度函数
True: 累积分布函数


实验2. 用Excel验证二项分布与泊松分布之间的关系。

实验过程:

	A	B	C	D	E	F
1	二项分布与泊松分布					
2		n= 20		$\lambda=$ 8		p= 0.2


1. 输入二项分布的参数 n, p 和泊松分布的参数 λ
2. 输入试验成功次数/事件数
3. 在B列第 i 行输入二项式分布计算公式 $=\text{BINOM.DIST}(A_i, \$B\$2, \$F\$2, \text{FALSE})$
4. 在C列第 i 行输入泊松分布计算公式 $=\text{POISSON.DIST}(A_i, \$D\$2, \text{FALSE})$

5. 做折线图。




实验2. 用Excel验证二项分布与泊松分布之间的关系。

实验结果：二项分布可用参数为 $\lambda = np$ 的泊松分布来近似。



$$\lambda = 4, n = 20, p = 0.2$$

$$\lambda = np$$




$$\lambda = 8, n = 20, p = 0.2$$


$$\lambda \neq np$$

实验2. 用Excel验证二项分布与泊松分布之间的关系。


实验结果：二项分布可用参数为 $\lambda = np$ 的泊松分布来近似， n 越大，越逼近。



$\lambda = 6, n = 20, p = 0.3$



$\lambda = 6, n = 50, p = 0.12$



$\lambda = 6, n = 100, p = 0.06$

回顾：n维随机变量的协方差矩阵

设 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的二阶混合中心矩

$$c_{ij} = \text{Cov}(X_i, X_j)$$

$$= E\{[X_i - E(X_i)][X_j - E(X_j)]\} \quad (i, j = 1, 2, \dots, n)$$

对每个 i, j 都存在,


$$\text{则称矩阵 } \Sigma = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}$$

为 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的协方差矩阵。

协方差矩阵&相关系数

□方法1：使用函数

- 协方差计算函数 `COVARIANCE.P(array1, array2)`
- 相关系数计算函数 `CORREL(array1, array2)`



实验3. 计算学生平时成绩、期中考试成绩、期末考试成绩两两之间的协方差和相关系数。

方法一:

Formula Bar f_x =COVARIANCE.P(B2:B61,A2:A61) **协方差**

A	B	C	D	E	F	G	H	I	J
期中成绩	期末成绩	作业成绩	总评			期中成绩	期末成绩	作业成绩	总评
32.00	18.00	0.00	16.80			183.749722			
78.00	80.00	47.00	69.50		期中成绩	180.757778			
38.00	32.00	0.00	24.20		期末成绩	195.258333			
75.00	54.00	59.00	61.80		作业成绩	186.005528			
42.00	40.00	0.00	28.60		总评				
49.00	70.00	0.00	42.70						
85.00	76.00	98.00	85.30						
62.00	59.00	99.00	71.90						


G11 f_x =CORREL(B2:B61,A2:A61) **相关系数**

	B	C	D	E	F	G	H	I	J
Enter	期中成绩	期末成绩	作业成绩	总评		期中成绩	期末成绩	作业成绩	总评
1	49.00	70.00	0.00	42.70		1			
7	85.00	76.00	98.00	85.30					
3	62.00	59.00	99.00	71.90					
9	49.00	71.00	89.00	69.80	期中成绩	0.72326613	1		
0	60.00	62.00	86.00	68.60	期末成绩	0.57371192	0.47803624	1	
1	76.00	75.00	91.00	80.10	作业成绩	0.85214907	0.86424705	0.83158367	1
2	61.00	48.00	96.00	66.30	总评				
3	76.00	62.00	92.00	75.20					
4	71.00	63.00	97.00	75.60					
5	87.00	78.00	88.00	83.70					
6									


协方差矩阵&相关系数

□方法1：使用函数


- 协方差计算函数 **COVARIANCE.P(array1, array2)**
- 相关系数计算函数 **CORREL(array1, array2)**



□方法2：使用数据分析工具箱



加载和激活分析工具库



实验3. 计算学生平时成绩、期中考试成绩、期末考试成绩两两之间的协方差和相关系数。

方法二:

1. Click the **Data** tab in the ribbon.

2. Click the **Data Analysis** button in the Analysis Tools group.

3. In the **Data Analysis** dialog box, select **Covariance**.

4. Click the **OK** button.

5. In the **Covariance** dialog box, specify the **Input Range** as $\$A\$1:\$D\61 .

6. Check the **Labels in first row** option.

7. Specify the **Output Range** as $\$F\$32:\$I\47 .

8. Click the **OK** button to complete the calculation.


	期中成绩	期末成绩	作业成绩	总评
期中成绩	183.74972			
期末成绩	180.75778	339.915556		
作业成绩	195.25833	221.283333	630.383333	
总评	186.00553	256.578556	336.205833	259.29483

拓展：主成分分析


Principal Component Analysis

低维数据的可视化

2维变量的观察空间



3维变量观察空间



难以观察4维及以上的更高维空间

如何对高维数据进行可视化分析?

□ 65个病人的53种化验指标，矩阵格式表示 (65x53)


化验指标

	H-WBC	H-RBC	H-Hgb	H-Hct	H-MCV	H-MCH	H-MCHC
A1	8.0000	4.8200	14.1000	41.0000	85.0000	29.0000	34.0000
A2	7.3000	5.0200	14.7000	43.0000	86.0000	29.0000	34.0000
A3	4.3000	4.4800	14.1000	41.0000	91.0000	32.0000	35.0000
A4	7.5000	4.4700	14.9000	45.0000	101.0000	33.0000	33.0000
A5	7.3000	5.5200	15.4000	46.0000	84.0000	28.0000	33.0000
A6	6.9000	4.8600	16.0000	47.0000	97.0000	33.0000	34.0000
A7	7.8000	4.6800	14.7000	43.0000	92.0000	31.0000	34.0000
A8	8.6000	4.8200	15.8000	42.0000	88.0000	33.0000	37.0000
A9	5.1000	4.7100	14.0000	43.0000	92.0000	30.0000	32.0000

难以从中发现各项指标之间的相关性

如何对高维数据进行可视化分析？


□ 谱图形式表示 (65幅图，每人1幅)



难以对不同病人进行横向比较

如何对高维数据进行可视化分析？

□ 谱图形式表示 (53幅图，每个指标1幅)



难以发现不同指标之间的关系


如何对高维数据进行可视化分析？

- 是否存在一种比已有坐标空间更好的表示？
- 是否确有必要观察所有53项指标？
 - 例如：具有强相关性的指标
- 是否能找到一个**维度尽可能小**的子空间（包含于原始的53维空间），并**尽可能多的**保留原始数据中的**信息**
- 解决方案
 - 主成分分析（Principal Component Analysis，简称PCA）

Principle Component Analysis 基本思想

□ 给定 d 维观察空间的数据点，将其投影到更低维度的空间，同时保持尽可能多的信息

- 投影后数据可区分性好（即分得越“开”越好）：
最大化投影后数据的方差
- 投影后的低维数据能重构高维原始数据：最小化原始数据点与重构数据点之间的均方误差






$$\min \| \underbrace{X}_{\text{原始数据}} - \underbrace{W * W^T X}_{\text{投影矩阵}} \|^2$$

重构数据

Principle Component Analysis 基本思想(方差角度)

□ 我们要寻找这样一些投影方向，即主成分向量(The Principal Components)：

- 它们以数据分布**最集中区域的中心**为**原点**向外发射的一组向量，即低维空间的基向量
- 第1个投影方向对应于数据分布**方差最大**的方向
- 第1、2、 $\dots$ 、 n 个投影方向
 - 与之前的投影方向相互**正交**
 - 对应于剩余**补空间**中的**方差最大**的方向



求解算法：利用协方差矩阵

□ 给定 m 个 n 维数据点 $\{x_1, \dots, x_m\}$ ，其中 $x_i \in \mathbb{R}^n$ ，计算
协方差矩阵

$$\Sigma = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^\top, \text{ 其中 } \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

□ 对 Σ 做奇异值分解，选取**最大的** k 个**特征值**对应的**特征向量**作为投影相量，将 n 维数据投影至 k 维空间

PCA 投影方向向量 = 协方差矩阵 Σ 的**特征向量**
特征值越大 $\Rightarrow$ 携带的信息越多


特征值/向量理解

如果把矩阵看作是运动，
特征值对应于“**运动速度**”，
特征向量对应于“**运动方向**”。


应用：高维数据可视化

COVID-19病人的基因表达分析

ACTB	ACTG1	ADRBK1	AHNAK	ALAS2	ANXA1
ANXA2	APLP2	ARL4C	B2M	BTG1	BTG2
C1orf63	CCR7	CD14	CD163	CD69	CD74
CD83	CLU	COX1	CTSB	CTSS	CXCR4
CYFIP2	DDX3X	DDX5	DNAJB1	DUSP1	DUSP2
EEF1A1	EIF1	EIF4G2	ENO1	F13A1	FCN1
FLNA	FOS	FOSB	FTL	GAPDH	GLUL
GPR183	GRN	HBA1	HBA2	HBB	HLA-B
HLA-DPA1	HLA-DRA	HLA-DRB1	HLA-DRB5	HLA-E	HMHA1
HSP90B1	HSPA5	HSPA8	IFI27	IFITM3	IGJ
IL10RA	IL1B	IRF1	ISG15	ITGA2B	ITGB2
IVNS1ABP	JAK1	JUNB	JUND	KLF2	KLF6
LCK	LCP1	LOC100507709	LOC100507714	MAFB	MCL1
MX1	NFKBIA	NFKBIZ	NR4A1	NR4A2	PIK3IP1
PKM2	PLBD1	PNRC1	PPBP	PPP1R15A	PSAP
PTGER4	PTPRC	RGS2	RPL13	RPL3	RPS2
S100A12	S100A8	S100A9	SELL	SERPINA1	SF3B1
SH3BGRL3	SLC2A3	SORL1	SPARC	SRSF5	SRSF7
SUN2	TAGAP	TLN1	TMEM66	TNFAIP3	TNFRSF1B
TSC22D3	TUBA1A	TYMP	UBC	VCAN	YPEL5
ZFP36	ZFP36L2	ZNF331			




应用：图片压缩



372x492 image

31x41
patches




PCA降维

应用：图片压缩



372x492 image



对144D的向量进行PCA降维，
重构误差与PCA维度的关系

应用：图片压缩

144D (原始)



60D



16D




6D




3D



1D



应用：图片压缩



特征值最大的60个特征向量


应用：人脸识别

- 给定一些人的照片，如何识别其身份
 - 需要考虑到对眼镜、不同光照等外部影响因素的稳定性
- ⇒ 不能仅仅使用原始输入的 256×256 大小图像中的像素信号



应用: 3D人脸形变统计模型

- 200张成年人3D人头模型, 每个模型含大约70000个顶点
- 经过PCA处理, 得到参数化人脸模型, 分成两个向量



形状 $S = (X_1, Y_1, Z_1, X_2, \dots, Y_n, Z_n)^T \in R^{3n}$

纹理 $T = (R_1, G_1, B_1, R_2, \dots, G_n, B_n)^T \in R^{3n}$

- 任意新的一个人脸都可由特征向量线性组合生成

形状 $S = \bar{S} + \sum a_i \mathbf{S}_i$

纹理 $T = \bar{T} + \sum b_i \mathbf{T}_i$ 满足 $\sum a_i = \sum b_i = 1$

应用：3D人脸形变统计模型

