

第五章：大数定律及中心极限定理

习题课

- 一、重点与难点**
- 二、主要内容**
- 三、典型例题**

一、重点及难点

1. 重点

- 利用切比雪夫不等式和中心极限定理估计和近似计算概率。
- 了解正态分布在近似计算中的作用。

2. 难点

- 证明随机变量服从大数定律。

二、主要内容

依概率收敛的定义

(弱) 大数定律的定义

切比雪夫不等式

Chebyshev
大数定律

Poisson
大数定律

Bernoulli
大数定律

Kinchin
大数定律

Markov
大数定律

中心极限定理的定义

独立同分布的
中心极限
定理

De Moivre
- Laplace
定理

Lyapunov
定理

切比雪夫 (Chebyshev) 不等式


□ 回顾：切比雪夫 (Chebyshev) 不等式

设随机变量 X 的**期望和方差都存在**，设期望 $E(X) = \mu$ ，方差 $D(X) = \sigma^2$ ，则对于任意正数 ϵ ，有

$$P\{|X - \mu| \geq \epsilon\} \leq \frac{\sigma^2}{\epsilon^2}$$

$$\left(\text{等价地：} P\{|X - \mu| < \epsilon\} \geq 1 - \frac{\sigma^2}{\epsilon^2} \right)$$

$$\begin{aligned} P\{|X - \mu| \geq \epsilon\} &= \int_{|x - \mu| \geq \epsilon} f(x) dx \\ &\leq \int_{|x - \mu| \geq \epsilon} \frac{|x - \mu|^2}{\epsilon^2} f(x) dx \leq \frac{\sigma^2}{\epsilon^2} \end{aligned}$$



依概率收敛

□定义： 设 $Y_1, Y_2, \dots, Y_n, \dots$ 是一个随机变量序列， a 是一个常数，若对任意正数 ε ，有

$$\lim_{n \rightarrow \infty} P\{|Y_n - a| < \varepsilon\} = 1,$$

则称**序列** $\{Y_n\}$ **依概率收敛于** a ，记为

$$Y_n \xrightarrow{P} a$$

(弱) 大数定律

□ **定义**: 设 $\{X_n, n = 1, 2, \dots\}$ 是一个随机变量序列, 而且对每个 n , $E(X_n)$ 存在, 如果对于任意给定的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| < \epsilon \right\} = 1$$

则称随机变量序列 $\{X_n\}$ 服从 (弱) 大数定律.

□ 等价形式:

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| > \epsilon \right\} = 0$$

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

常见的（弱）大数定律

□ 什么时候（弱）大数定律成立？

- 设随机变量序列 $\{X_n\}$

	$\{X_n\}$ 分布	$\{X_n\}$ 是否 两两独立	$E(X_i)$	$D(X_i)$
Chebyshev大数定律	—	是	存在	存在且有界
Poisson大数定律	0-1分布	是	存在	存在且有界
Bernoulli大数定律	同分布 0-1分布	是	存在	存在且有界
Khinchin大数定律	同分布	是	存在	可以不存在
Markov大数定律	—	否	存在	$\lim_{n \rightarrow \infty} D\left(\frac{1}{n} \sum_{k=1}^n X_k\right) = 0$

切比雪夫(Chebyshev)大数定律

设随机变量序列 $\{X_n\}$ 满足如下条件：

- (1) $X_1, X_2, \dots, X_n, \dots$ **两两相互独立**；
- (2) 对每一个 $n(n = 1, 2, \dots)$ ， **$D(X_n)$ 存在**；
- (3) 数列 **$\{D(X_n)\}$ 有界**，即存在常数 c ，使得对于任意的 $n(n = 1, 2, \dots)$ ，有 $D(X_n) \leq c$ ，则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| < \epsilon \right\} = 1$$

即随机变量序列 $\{X_n\}$ 服从大数定律

切比雪夫 (Chebyshev) 大数定律的特殊形式

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 是**独立同分布**的随机变量，且 **$E(X_k) = \mu, D(X_k) = \sigma^2$** ($k = 1, 2, \dots$)，做前 n 个随机变量的算术平均

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$$

则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\{|\bar{X} - \mu| < \epsilon\} = \lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| < \epsilon\right\} = 1$$

泊松 (Poisson) 大数定律

如果在**独立**试验序列中，事件 A 在第 n 次试验中出现概率为 p_n ，设 n_A 是前 n 次试验中事件 A 出现的次数，则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{n_A}{n} - \frac{p_1 + p_2 + \cdots + p_n}{n} \right| < \epsilon \right\} = 1$$

Bernoulli大数定律

设 f_A 是 n 次**独立重复**试验中事件 A 发生的次数， p 是事件 A 在每次试验中发生的概率，则对于任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| < \epsilon \right\} = 1$$

或

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| > \epsilon \right\} = 0$$

Khinchin大数定律

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 是**独立同分布**的随机变量序列，且**具有数学期望** $E(X_k) = \mu$, ($k = 1, 2, \dots$)，
做前 n 个变量的算术平均

$$\frac{1}{n} \sum_{k=1}^n X_k$$

则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \epsilon \right\} = 1$$

注意：与前面Chebyshev大数定律的特殊情况相比，这里**没有要求** $D(X_n)$ **存在**

Markov大数定律

设随机变量 $\{X_n\}$ 是随机变量序列，如果

$$\lim_{n \rightarrow \infty} D \left(\frac{1}{n} \sum_{k=1}^n X_k \right) = 0 \text{ (称为Markov条件),}$$

则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| < \epsilon \right\} = 1$$

不要求随机变量的独立性，因此提供了一种研究非独立随机变量序列服从大数定律的方法。

大数定律的关系

大数定律的一般形式

对随机变量序列 $\{X_n\}$ ($n = 1, 2, \dots$), $E(X_n)$ 存在,

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

不要求独立同分布

Khinchin大数定律

$X_1, X_2, \dots, X_n, \dots$ 独立同分布,
 $E(X_k) = \mu, (k = 1, 2, \dots)$

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

Bernoulli 试验

Bernoulli大数定律

n 次独立重复试验发生
 f_A 次, p 是每次试验中
发生的概率

$$\frac{f_A}{n} \xrightarrow{P} p$$

0-1分布

不要求方差的
存在性

Bernoulli试验

Poisson大数定律

n 次独立试验发生 f_A 次,
第 k 次发生概率为 p_k

$$\frac{n_A}{n} \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n p_k$$

0-1分布

独立同分布

独立同分布下的
Chebyshev大数定律

$E(X_k) = \mu, D(X_k)$ 存在
($k = 1, 2, \dots$)

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

Markov大数定律

随机变量序列 $\{X_n\}$, $E(X_n)$ 存在, 且

$$\lim_{n \rightarrow \infty} D\left(\frac{1}{n} \sum_{k=1}^n X_k\right) = 0 \text{ (Markov条件)}$$

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

不要求
独立性,
但对方
差有约
束

Chebyshev大数定律

$X_1, X_2, \dots, X_n, \dots$ 两两相互独立
 $E(X_n), D(X_k)$ 存在 ($k = 1, 2, \dots$)

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \frac{1}{n} \sum_{k=1}^n E(X_k)$$

中心极限定理

□ **定义**：设 $X_1, X_2, \dots, X_n, \dots$ 是**独立**的随机变量序列，若 $E(X_k)$, $D(X_k)$ ($k = 1, 2, \dots$) **都存在**，令

$$Y_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n E(X_k)}{\sqrt{\sum_{k=1}^n D(X_k)}}$$

若对任意 $x \in R$ ，有，

$$\lim_{n \rightarrow \infty} P\{Y_n \leq x\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

则称该随机变量序列服从**中心极限定理**。

等价地，若 $\{X_n\}$ 服从中心极限定理，则当 n **足够大** 时， Y_n 近似服从**标准正态分布**。

常见的中心极限定理

□ 设随机变量 $X_1, X_2, \dots, X_n, \dots$ **两两独立**

	$\{X_n\}$ 分布	$E(X_i)$	$D(X_i)$	Y_n
独立同分布的中心极限定理	同分布	μ	$\sigma_k^2 > 0$	$\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$
棣莫佛 - 拉普拉斯定理	同分布 0-1分布	$p \in (0,1)$	$p - p^2$	$\frac{\sum_{k=1}^n X_k - np}{\sqrt{np(1-p)}}$
李雅普诺夫定理	—	μ_i	$\sigma_k^2 > 0$; 且存在 $\delta > 0$, 使得当 $n \rightarrow \infty$ 时, $\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{ X_k - \mu_k ^{2+\delta}\} \rightarrow 0$	$\frac{\sum_{k=1}^n X_k - (\sum_{k=1}^n \mu_k)}{\sqrt{D(\sum_{k=1}^n X_k)}}$

独立同分布的中心极限定理 (Lindburg-Levy定理)

设随机变量 $X_1, X_2, \dots, X_n, \dots$ **独立同分布**，且 **$E(X_k) = \mu$** ， **$D(X_k) = \sigma^2 > 0$** ， **$(k = 1, 2, \dots)$** ，则随机变量之和 $\sum_{k=1}^n X_k$ 的标准化变量

$$Y_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$$

的分布函数 $F_n(x)$ 对于任意的 x 满足

$$\begin{aligned} F_n(x) &= \lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x \right\} \\ &= \int_{-\infty}^x \frac{e^{-\frac{t^2}{2}}}{\sqrt{2\pi}} dt = \Phi(x) \end{aligned}$$

李雅普诺夫 (Lyapunov) 定理

设随机变量 $X_1, X_2, \dots, X_n, \dots$ **相互独立**, 且 $E(X_k) = \mu_k$, $D(X_k) = \sigma_k^2 > 0$, ($k = 1, 2, \dots$), 记 $B_n^2 = \sum_{k=1}^n \sigma_k^2$,
若存在 $\delta > 0$, 使得当 $n \rightarrow \infty$ 时

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{|X_k - \mu_k|^{2+\delta}\} \rightarrow 0$$

则随机变量之和 $\sum_{k=1}^n X_k$ 的标准化变量

$$Z_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n}$$

的分布函数 $F_n(x)$ 对于任意的 x 满足

$$\begin{aligned} \lim_{n \rightarrow \infty} F_n(x) &= \lim_{n \rightarrow \infty} P\left\{\frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n} \leq x\right\} \\ &= \int_{-\infty}^x \frac{e^{-\frac{t^2}{2}}}{\sqrt{2\pi}} dt = \Phi(x) \end{aligned}$$

棣莫佛—拉普拉斯 (De Moivre – Laplace) 定理

设随机变量 $\eta_n (n = 1, 2, \dots)$ 服从参数为 n, p ($0 < p < 1$)的**二项分布**，则对于任意 x ，有

$$\lim_{n \rightarrow \infty} P \left\{ \frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \Phi(x)$$

De Moivre-Laplace定理可以认为是**独立同分布的中心极限定理**的一个**特例**： η_n 可以分解成 **n 个相互独立、服从同一（0-1）分布**的随机变量 $X_1, X_2, \dots, X_n$ **之和**。

二项分布的逼近

对于一个参数为 n , p 的二项分布, 当 $n \rightarrow \infty$ 时:

(1) 若 $np = \lambda$, 则该二项分布逼近参数为 λ 的泊松分布; **泊松定理**

(2) 若 $np \rightarrow \infty$, 则该二项分布逼近正态分布。

De Moivre – Laplace定理

在实际计算中:

如果 n 很大, 但是 p 很小或 $q = 1 - p$ 很小, 应该用泊松定理去近似二项分布;

如果 n , np 和 nq 都较大, 应该用中心极限定理去近似。

三个中心极限定理

不要求同
分布, 但
要求方差
满足收敛
性

Lyapunov定理

$\{X_n\}$ 独立, 且 $E(X_k) = \mu_k$, $D(X_k) = \sigma_k^2 > 0$,
 $B_n^2 = \sum_{k=1}^n \sigma_k^2$,

若存在 $\delta > 0$, 使得当 $n \rightarrow \infty$ 时

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{|X_k - \mu_k|^{2+\delta}\} \rightarrow 0$$
$$\lim_{n \rightarrow \infty} Z_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n} \sim N(0,1)$$

独立同分布的中心极限定理

$\{X_n\}$ 独立同分布, 且 $E(X_k) = \mu$, $D(X_k) = \sigma^2 > 0$, ($k = 1, 2, \dots$),

$$\lim_{n \rightarrow \infty} Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \sim N(0,1)$$

二项分布
逼近

De Moivre – Laplace定理

$\eta_n \sim b(n, p)$ ($0 < p < 1$), 则对于任意 x , 有

$$\lim_{n \rightarrow \infty} \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1)$$

三、典型例题

题型1：证明依概率收敛性

例1. 设独立同分布随机变量序列 $\{X_n\}$ 均服从 $[0, a]$ 上的均匀分布，令

$$Y_n = \max(X_1, X_2, \dots, X_n),$$

试证明： $Y_n \xrightarrow{P} a$.

【思路】 要证 $Y_n \xrightarrow{P} a$ ，即证对任给的 $\epsilon > 0$ ，有
$$\lim_{n \rightarrow \infty} P\{|Y_n - a| > \epsilon\} = 0,$$

因此，只需要先求出概率 $P\{|Y_n - a| > \epsilon\}$ 即可。

证: 由于 $\{X_n\}$ 均服从 $[0, a]$ 上的均匀分布, 因此, 对任意 n , 当 $\epsilon > a$ 时, 有

$$P\{Y_n > \epsilon\} = 0.$$

对任意的 $0 < \epsilon < a$, 有

$$\begin{aligned} & P\{|Y_n - a| > \epsilon\} \\ &= P\{Y_n < a - \epsilon\} + P\{Y_n > a + \epsilon\} \\ &= P\{Y_n < a - \epsilon\} \\ &= P\{\max(X_1, X_2, \dots, X_n) < a - \epsilon\} \\ &= P\{X_1 < a - \epsilon, X_2 < a - \epsilon, \dots, X_n < a - \epsilon\} \\ &= P\{X_1 < a - \epsilon\}P\{X_2 < a - \epsilon\} \dots P\{X_n < a - \epsilon\} \\ &= \left(\frac{a - \epsilon}{a}\right)^n \quad \text{从而} \lim_{n \rightarrow \infty} P\{|Y_n - a| > \epsilon\} = 0, \text{ 即 } Y_n \xrightarrow{P} a. \end{aligned}$$

例2. 设 $X_1, X_2, \dots, X_n$ 是独立同分布的随机变量序列,
 $E(X_i) = \mu$, $D(X_i) = \sigma^2$ 均存在, 证明

$$Y_n = \frac{2}{n(n+1)} \sum_{i=1}^n iX_i \xrightarrow{P} \mu.$$

【思路】：由依概率收敛的定义，
即证 $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P\{|Y_n - \mu| < \varepsilon\} = 1$;

即 $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P\{|Y_n - \mu| \geq \varepsilon\} = 0$ 。

考虑到 $E(Y_n) = \mu$, $D(Y_n)$ 存在, 可由切比雪夫不等式证出。

证：因为 $E(Y_n) = E\left\{\frac{2}{n(n+1)}\sum_{i=1}^n iX_i\right\}$

$$= \frac{2}{n(n+1)}\sum_{i=1}^n iE(X_i)$$

$$= \frac{2\mu}{n(n+1)}\sum_{i=1}^n i = \mu$$

$$D(Y_n) = \frac{4}{n^2(n+1)^2}\sum_{i=1}^n i^2 D(X_i) = \frac{4\sigma^2}{n^2(n+1)^2}\sum_{i=1}^n i^2$$

$$= \frac{4n(n+1)(2n+1)\sigma^2}{6n^2(n+1)^2} = \frac{2(2n+1)\sigma^2}{3n(n+1)}$$

随机变量 Y_n 的数学期望 $E(Y_n) = \mu$, 且方差 $D(Y_n)$ 存在, 则对于任意正数 $\varepsilon > 0$, 由切比雪夫不等式得:

$$P\{|Y_n - \mu| \geq \varepsilon\} \leq \frac{D(Y_n)}{\varepsilon^2} = \frac{2\sigma^2(2n+1)}{2n(n+1)\varepsilon^2}$$

$$\lim_{n \rightarrow \infty} P\{|Y_n - \mu| \geq \varepsilon\} \leq \lim_{n \rightarrow \infty} \frac{2\sigma^2(2n+1)}{2n(n+1)\varepsilon^2} = 0$$

即 $Y_n \xrightarrow{P} \mu$.

作业题 《概率论及其应用》 Chpt. 10, 7:

设 $\{X_k\}$ 是相互独立的具有同分布的随机变量序列，且有均值 μ 和有限的方差。令 $S_n = X_1 + X_2 + \cdots + X_n$ 。试证：大数定律对随机变量序列 $\{S_n\}$ 不成立。如果 $na_n \rightarrow 0$ ，则 $\{a_n S_n\}$ 服从大数定律。

思路：（1）弱大数定律的定义要求：如果 $\{S_n\}$ 满足大数定律，那么对于每个 n ， $E(S_n)$ 存在，并且对于任意给定的 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n S_k - \frac{1}{n} \sum_{k=1}^n E(S_k) \right| < \epsilon \right\} = 1$$

考虑用反证法证明。如果 $\{S_n\}$ 服从大数定律，则可以推出 $\lim_{n \rightarrow \infty} D \left(\frac{1}{n} \sum_{i=1}^n S_n \right) = 0$ ；但是事实上 $\lim_{n \rightarrow \infty} D \left(\frac{1}{n} \sum_{i=1}^n S_n \right) = \infty$ 。因此，得出假设不成立。

证明: (1) 假设 $\{S_n\}$ 满足大数定律, 则 $\overline{S_n} = \frac{1}{n} \sum_{i=1}^n S_i$ 依概率收敛到 $ES = \frac{1}{n} \sum_{i=1}^n E(S_i)$, 即对任意 $\varepsilon > 0$, 都有

$$\lim_{n \rightarrow \infty} P\{|\overline{S_n} - ES| < \varepsilon\} = 1。$$

$$\text{又 } \lim_{n \rightarrow \infty} D(\overline{S_n}) = \lim_{n \rightarrow \infty} E \left[\left(\overline{S_n} - E(\overline{S_n}) \right)^2 \right] = \lim_{n \rightarrow \infty} \int \left(\overline{S_n} - E(\overline{S_n}) \right)^2 p(\overline{S_n}) d\overline{S_n}$$

则对任意 $\varepsilon > 0$, 都有

$$\begin{aligned} \lim_{n \rightarrow \infty} D(\overline{S_n}) &= \lim_{n \rightarrow \infty} \left\{ \int_{|\overline{S_n} - E(\overline{S_n})| < \varepsilon} \left(\overline{S_n} - E(\overline{S_n}) \right)^2 p(\overline{S_n}) d\overline{S_n} + \right. \\ &\quad \left. \int_{|\overline{S_n} - E(\overline{S_n})| \geq \varepsilon} \left(\overline{S_n} - E(\overline{S_n}) \right)^2 p(\overline{S_n}) d\overline{S_n} \right\} \end{aligned}$$

$$\leq \varepsilon^2 \lim_{n \rightarrow \infty} P\{|\overline{S_n} - ES| < \varepsilon\} +$$

$$\lim_{n \rightarrow \infty} P\{|\overline{S_n} - ES| \geq \varepsilon\} \sup_{|\overline{S_n} - ES| \geq \varepsilon} (\overline{S_n} - ES)^2$$

$$= \varepsilon^2 \cdot 1 + 0 = \varepsilon^2 \quad 0$$

取 $\varepsilon \rightarrow 0$, 即可得 $\lim_{n \rightarrow \infty} D(\overline{S_n}) \rightarrow 0$ 。

但是，又因为

$$\begin{aligned}
 \lim_{n \rightarrow \infty} D(\overline{S_n}) &= \lim_{n \rightarrow \infty} D\left(\frac{1}{n} \sum_{i=1}^n S_i\right) = \lim_{n \rightarrow \infty} \frac{1}{n^2} D(S_1 + S_2 + \cdots + S_n) \\
 &= \lim_{n \rightarrow \infty} \frac{1}{n^2} D[X_1 + (X_1 + X_2) + \cdots + (X_1 + X_2 + \cdots + X_n)] \\
 &= \lim_{n \rightarrow \infty} \frac{1}{n^2} D[nX_1 + (n-1)X_2 + (n-2)X_3 + \cdots + X_n] \\
 &= \lim_{n \rightarrow \infty} \frac{1}{n^2} [n^2 D(X_1) + (n-1)^2 D(X_2) + \cdots + D(X_n)]
 \end{aligned}$$

由题意知 $\{X_i\}$ 有有界的方差，不妨设方差为 $0 < D(X_2) = \sigma^2 < \infty$ ，则

$$\begin{aligned}
 \lim_{n \rightarrow \infty} D(\overline{S_n}) &= \lim_{n \rightarrow \infty} \frac{\sigma^2}{n^2} (1 + 4 + \cdots + n^2) = \lim_{n \rightarrow \infty} \frac{\sigma^2 n(n+1)(2n+1)}{6} \\
 &= \lim_{n \rightarrow \infty} \frac{\sigma^2 n}{6} = \infty \quad \text{与} \quad \lim_{n \rightarrow \infty} D(\overline{S_n}) \rightarrow 0 \text{ 矛盾。}
 \end{aligned}$$

因此，假设不成立，即 $\{S_n\}$ 不满足大数定律。

思路：（2）先证明随机变量 $\overline{Y}_n = \frac{1}{n} \sum_{i=1}^n a_i S_i$ 的期望 $E(\overline{Y}_n)$ 和方差 $D(\overline{Y}_n)$ 存在；再根据切比雪夫不等式 $P\{|\overline{Y}_n - E(\overline{Y}_n)| < \varepsilon\} \geq 1 - \frac{D(\overline{Y}_n)}{\varepsilon^2}$ 可得证。

证明： 因为 $na_n \rightarrow 0$ ，所以 a_n 有界。

不妨设存在 M ，使得 $a_n < M$ ， $n=1,2,\dots$

令 $\overline{Y}_n = \frac{1}{n} \sum_{i=1}^n a_i S_i$ ，则

$$\begin{aligned} E(\overline{Y}_n) &= E\left(\frac{1}{n} \sum_{i=1}^n a_i S_i\right) = \frac{1}{n} \sum_{i=1}^n a_i E(S_i) \\ &= \frac{1}{n} \sum_{i=1}^n a_i \mu < \frac{nM\mu}{n} = M\mu \end{aligned}$$

所以 $\overline{Y}_n$ 的期望存在。

$$\begin{aligned}
 D(\overline{Y}_n) &= D\left(\frac{1}{n} \sum_{i=1}^n a_i S_i\right) = \frac{1}{n^2} D\left(\sum_{i=1}^n a_i S_i\right) \\
 &= \frac{1}{n^2} D[a_1 X_1 + a_2(X_1 + X_2) + \cdots a_n(X_1 + X_2 + \cdots + X_n)] \\
 &= \frac{1}{n^2} D[(a_1 + a_2 + \cdots a_n)X_1 + (a_2 + \cdots a_n)X_2 + \cdots a_n X_n] \\
 &= \frac{1}{n^2} [(a_1 + a_2 + \cdots a_n)^2 \sigma^2 + (a_2 + \cdots a_n)^2 \sigma^2 + \cdots a_n^2 \sigma^2] \\
 &= \left[\left(\frac{a_1 + a_2 + \cdots + a_n}{n}\right)^2 + \left(\frac{a_2 + \cdots + a_n}{n}\right)^2 + \cdots + \left(\frac{a_n}{n}\right)^2 \right] \sigma^2
 \end{aligned}$$

当 $n \rightarrow \infty$ 时, $D(\overline{Y}_n) \rightarrow 0$

↓
0

所以 $D(\overline{Y}_n)$ 有界, Y_n 的方差存在。

已知 $\lim_{n \rightarrow \infty} na_n = 0$, 以下证明当 $n \rightarrow +\infty$ 时,

$$\left(\frac{a_1 + a_2 + \cdots + a_n}{n}\right)^2 + \left(\frac{a_2 + \cdots + a_n}{n}\right)^2 + \cdots + \left(\frac{a_n}{n}\right)^2 \rightarrow 0 \quad \text{式(1)}$$

因为 $\lim_{n \rightarrow \infty} na_n = 0$, 所以 na_n 有界, 不妨设 $\forall n, na_n < A$, 即 $|a_n| \leq \frac{A}{n}$ 。

$$\text{令 } f_k = (a_k + a_{k+1} + \cdots + a_n)^2 = \sum_{k \leq i, j \leq n} a_i a_j$$

$$\begin{aligned} &= \sum_{k \leq i, j \leq n} \frac{(ia_i)(ja_j)}{ij} < A^2 \sum_{k \leq i, j \leq n} \frac{1}{ij} = A^2 \left(\sum_{k \leq i \leq n} \frac{1}{i} \right)^2 \\ &\sim \left(A \int_{k-1}^n \frac{1}{x} dx \right)^2 = A^2 (\ln n - \ln(k-1))^2 \end{aligned}$$

式(1)左边为

$$\sum_{k=1}^n \frac{f_k}{n^2} < \frac{A^2}{n^2} \left((\ln n)^2 + \sum_{k=2}^n (\ln n - \ln(k-1))^2 \right)$$

$$\sim \frac{A^2}{n^2} \int_1^{n-1} (\ln(n) - \ln(x))^2 dx \xrightarrow{x=nt} \frac{A^2}{n^2} n \int_1^{n-1} \ln(t)^2 dt = \frac{2A^2}{n} \rightarrow 0,$$

当 $n \rightarrow +\infty$ 时, 式(1)成立

因为 $\overline{Y_n}$ 的期望和方差存在, 所以对任意正数 $\varepsilon > 0$, 由切比雪夫不等式得

$$P\{|Y_n - E(Y_n)| < \varepsilon\} \geq 1 - \frac{D(Y_n)}{\varepsilon^2}$$

$$\text{即 } P\left\{\left|\frac{1}{n}\sum_{i=1}^n a_i S_i - \frac{1}{n}\sum_{i=1}^n E(a_i S_i)\right| < \varepsilon\right\} \geq 1 - \frac{D(Y_n)}{\varepsilon^2}.$$

取 $n \rightarrow \infty$, 则有

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n}\sum_{i=1}^n a_i S_i - \frac{1}{n}\sum_{i=1}^n E(a_i S_i)\right| < \varepsilon\right\} \geq 1 - \frac{\lim_{n \rightarrow \infty} D(Y_n)}{\varepsilon^2} = 1$$

所以 $\{a_n S_n\}$ 满足大数定律。

作业题 《概率论及其应用》 Chpt. 10, 8:

设 $\{X_k\}$ 是一个随机变量序列，其中 X_k 只与 X_{k-1} 和 X_{k+1} 相依而与其它 $X_j (j \neq k-1, k+1)$ 相互独立，而且 $D(X_k)$ 有界，试证 $\{X_k\}$ 服从大数定律。

思路：不独立的随机变量，根据Markov大数定律，判断

$\lim_{n \rightarrow \infty} D\left(\frac{1}{n} \sum_{k=1}^n X_k\right) = 0$ 是否满足。

证明： $D(X_k)$ 有界，不妨设 $D(X_k) \leq M, \forall k$.

$$\begin{aligned}
 \lim_{n \rightarrow \infty} D\left(\frac{1}{n} \sum_{k=1}^n X_k\right) &= \lim_{n \rightarrow \infty} \frac{1}{n^2} D\left(\sum_{k=1}^n X_k\right) \\
 &= \lim_{n \rightarrow \infty} \frac{1}{n^2} \left(\sum_{k=1}^n D(X_k) + 2 \sum_{i \neq j}^n \text{Cov}(X_i, X_j) \right) \\
 &= \lim_{n \rightarrow \infty} \frac{1}{n^2} \left(\sum_{k=1}^n D(X_k) + 2 \sum_{i=1}^{n-1} \text{Cov}(X_i, X_{i+1}) \right) \\
 &= \lim_{n \rightarrow \infty} \frac{1}{n^2} \left(\sum_{k=1}^n D(X_k) + 2 \sum_{i=1}^{n-1} \rho_{X_i X_{i+1}} \sqrt{D(X_i)} \sqrt{D(X_{i+1})} \right) \\
 &\leq \lim_{n \rightarrow \infty} \frac{1}{n^2} \left(\sum_{k=1}^n M + 2 \sum_{i=1}^{n-1} \sqrt{M} \sqrt{M} \right) = 0
 \end{aligned}$$

题型2：利用中心极限定理估算概率

例3. 设每颗炮弹命中目标的概率为0.01，求500发炮弹中命中5发的概率.

解： 设 X 表示命中的炮弹数，则 $X \sim b(500, 0.01)$

$$(1) P(X = 5) = C_{500}^5 \times 0.01^5 \times 0.99^{495} = 0.17635$$

(2) 应用正态逼近，近似地 $\frac{X - 500 \times 0.01}{\sqrt{500 \times 0.01 \times 0.99}} \sim N(0, 1)$

$$\begin{aligned} P(X = 5) &= P(4.5 < X < 5.5) \\ &\approx \Phi\left(\frac{5.5 - 5}{\sqrt{4.95}}\right) - \Phi\left(\frac{4.5 - 5}{\sqrt{4.95}}\right) = 0.1742 \end{aligned}$$

“标准化”和“正态近似”， n 越大所得的近似值越精确。

例4. 100个独立工作(工作的概率为0.9)的部件组成一个系统，求系统中至少有85个部件工作的概率。

【思路】中心极限定理.

解：令 $X_i = 1$ 表示第 i 个部件正常工作，反之记为 $X_i = 0$ ， $E(X_i) = 0.9$ ， $D(X_i) = 0.09$ 。记 $Y = X_1 + X_2 + \cdots + X_{100}$ ，因为 X_i 独立同分布，则随机变量序列 $\{X_n\}$ 服从中心极限定理，即近似地


$$\frac{Y - 100E(X_i)}{\sqrt{100D(X_i)}} \sim N(0,1)$$

$$\begin{aligned} \text{由此得：} P\{Y \geq 85\} &= 1 - P\{Y \leq 85\} \\ &= 1 - \Phi\left(\frac{85-90}{\sqrt{9}}\right) = 0.9525 \end{aligned}$$

查课本P382页附表2标准正态分布表， $\Phi(1.67) = 0.9525$

附表 2 标准正态分布表

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$



x	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9278	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

习题课5: 大数定律及中心极限定理

$$\Phi(1.67) = 0.9525$$

例5. 有200台独立工作(工作的概率为0.7)的机床, 每台机床工作时需15kw电力。问共需多少电力, 才可有95%的可能性保证供电充足?

【思路】 中心极限定理.

解: 用 $X_i = 1$ 表示第 i 台机床正常工作, 反之记为 $X_i = 0$.

则 $E(X_i) = 0.7$, $D(X_i) = 0.21$. 记 $Y = X_1 + X_2 + \cdots + X_{200}$,

因为 X_i 独立同分布, 由中心极限定理有 $\frac{Y-200E(X_i)}{\sqrt{200D(X_i)}} \sim N(0,1)$.

设供电量为 y , 供电充足即为 $15Y \leq y$, 则

$$P\{15Y \leq y\} \approx \Phi\left(\frac{y/15-140}{\sqrt{42}}\right) \geq 0.95$$

解得: $y \geq 2260.4$

例6. 假设某大学中报名选修统计课的学生人数服从参数为100的泊松分布。负责开课的教授决定，如果学生的报名人数不少于120人，就分成两个班授课，如果少于120人，就集中在一个班讲授。试问：教授将讲授两个班的概率是多少？

【思路】 设报名选修统计课的学生人数为 X ，故所求概率为

$$P\{X \geq 120\} = 1 - \sum_{k=0}^{119} \frac{100^k e^{-100}}{k!}$$

上式计算量惊人，考虑应用中心极限定理求近似值。根据泊松分布的可加性，将随机变量 X （服从参数100的泊松分布）看成是100个相互独立的服从参数为1的泊松分布的随机变量之和。

解： 设报名选修统计课的学生人数为 $X \sim \mathcal{P}(100)$ ，
设随机变量 $X_1, X_2, \dots, X_{100}$ 相互独立且 $X_i \sim \mathcal{P}(1), i = 1, 2, \dots, 100$ 。由泊松分布的可加性知，

$$X_1 + X_2 + \dots + X_{100} \sim \mathcal{P}(100)。$$

又因为 $E(X_i) = 1, D(X_i) = 1, i = 1, 2, \dots, 100$ ，由独立同分布的中心极限定理可得

$$\begin{aligned} P\{X \geq 120\} &= P\{X_1 + X_2 + \dots + X_{100} \geq 120\} \\ &= P\left\{\frac{\sum_{i=1}^{100} X_i - 100}{\sqrt{100}} \geq \frac{120 - 100}{\sqrt{100}}\right\} \\ &\approx 1 - \Phi\left(\frac{120 - 100}{\sqrt{100}}\right) = 1 - \Phi(2) \\ &= 0.0228 \end{aligned}$$

例7. 用调查对象中的收看比例 k/n 作为某电视节目的收视率 p 的估计。要有90%的把握，使 k/n 与 p 的差异不大于0.05，问至少要调查多少对象？

【思路】 中心极限定理.

解：用 $X_i = 1$ 表示第 i 个调查对象观看某电视节目，否则 $X_i = 0$ ， $EX_i = p$ ， $DX_i = p(1-p)$ 。 $Y_n = X_1 + \cdots + X_n$ 表示前 n 个调查对象中观看节目的人数，因为 X_i 相互独立，所以 $\frac{Y_n - np}{\sqrt{np(1-p)}} \sim N(0,1)$ 。

根据题意： $P\left\{\left|\frac{Y_n}{n} - p\right| < 0.05\right\} = P\left\{\left|\frac{Y_n - np}{\sqrt{np(1-p)}}\right| <$

$$0.05 \sqrt{\frac{n}{p(1-p)}}\right\} \approx 2\Phi\left(0.05 \sqrt{\frac{n}{p(1-p)}}\right) - 1 \geq 0.90$$

解得： $n \geq 272.25$ ，即： $n = 273$

例8. 一生产线生产的产品成箱包装，每箱的重量是随机的。假设每箱平均重50千克，标准差为5千克。若用最大载重量为5吨的汽车承运，试利用中心极限定理说明每辆车最多可以装多少箱，才能保证不超载的概率大于0.977。

【思路】 独立同分布中心极限定理

解： 设 $X_i (i = 1, 2, \dots, n)$ 是装运第 i 箱的重量， n 是所求箱数，则载重量 $Y_n = X_1 + X_2 + \dots + X_n$ 是独立同分布的随机变量 $X_i (i = 1, 2, \dots, n)$ 之和。

$$\mu = EX_i = 50, \quad \sigma^2 = DX_i = 25 \quad (i = 1, 2, \dots, n).$$

根据独立同分布的中心极限定理知 $\frac{Y_n - 50n}{5\sqrt{n}}$ 的极限分布是标准正态分布。

$$\begin{aligned} P\{\text{不超载}\} &= P\{0 < Y_n \leq 5000\} \\ &= P\left\{\frac{0-50n}{5\sqrt{n}} < \frac{Y_n-50n}{5\sqrt{n}} < \frac{5000-50n}{5\sqrt{n}}\right\} \\ &\approx \Phi\left\{\frac{1000-10n}{\sqrt{n}}\right\} - \Phi\{-10\sqrt{n}\} > 0.977 \end{aligned}$$

解得 $\frac{1000-10n}{\sqrt{n}} > 2$ ，即 $n < 98.0199$ ，故最多可装98箱。

例9. 某保险公司的老年人寿保险有1万人参加, 每人每年交200元. 若老人在该年内死亡, 公司付给家属1万元. 设老年人死亡率为0.017, 试求保险公司在一年内的这项保险中亏本的概率.

解: 设 X 为一年中投保老人的死亡数, 则 X 服从二项分布 $B(n, p)$, 其中 $n = 10000$, $p = 0.017$.

由棣莫佛—拉普拉斯定理知保险公司亏本的概率:

$$\begin{aligned} P\{10000X > 10000 \times 200\} &= P\{X > 200\} \\ &= P\left\{\frac{X-np}{\sqrt{np(1-p)}} > \frac{200-np}{\sqrt{np(1-p)}}\right\} = P\left\{\frac{X-np}{\sqrt{np(1-p)}} > 2.321\right\} \\ &\approx 1 - \Phi\{2.321\} \approx 0.01. \end{aligned}$$

考试范围：第一章至第五章

考试时间：2025年11月25日（周二）

8:30-10:10

考试地点：教三楼119

第1章：随机事件与概率

第2章：随机变量及其分布

第3章：多维随机变量及其分布

第4章：随机变量的数字特征

第5章：大数定律及中心极限定理

第一章 随机事件与概率

习题课5：期中复习

厘清概念

随机试验

样本空间

随机事件



事件之间的关系

事件之间的运算

事件之间的运算法则

概率定义

条件概率

独立性



概率的性质

古典概型

几何概型

乘法公式

全概率公式

Bayes公式

Bernoulli概型



概率的计算

条件概率、乘法公式、全概率公式和贝叶斯公式

(1) 条件概率的定义、计算公式

✓ 公式法： $P(B|A) = \frac{P(AB)}{P(A)}$, ($P(A) > 0$)

✓ 缩小样本空间法：——适用于古典概型

设事件 A 所含样本点数为 n_A , 事件 AB 所含样本点数为 n_{AB} , 则

$$P(B|A) = \frac{n_{AB}}{n_A}$$

(2) 乘法公式

✓ $P(AB) = P(A)P(B|A)$, ($P(A) > 0$)

✓ $P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \cdots P(A_n|A_1 A_2 \cdots A_{n-1})$,
($P(A_1 A_2 \cdots A_{n-1}) > 0$)

(3) 全概率公式

$$P(A) = \sum_{i=1}^n P(AB_i) = \sum_{i=1}^n P(B_i)P(A|B_i) \quad (\text{已知原因, 求结果})$$

(4) Bayes (逆概) 公式

$$P(B_k|A) = \frac{P(AB_k)}{P(A)} = \frac{P(A|B_k)P(B_k)}{\sum_{i=1}^n P(A|B_i)P(B_i)}, \quad i = 1, 2, \dots, n$$

(已知结果, 求原因)

☛ 随机事件独立性概念，利用事件独立性进行概率计算

(1) 两事件独立的定义

$$P(AB) = P(A)P(B)$$

(2) 两事件独立性的性质

① 事件 A 与 B 相互独立的充分必要条件为

$$P(B|A) = P(B), (P(A) > 0),$$

② 若随机事件 A 与 B 相互独立，则
 $\bar{A}$ 与 B 、 A 与 $\bar{B}$ 、 $\bar{A}$ 与 $\bar{B}$ 也相互独立.

③ 必然事件 S 与任意随机事件 A 相互独立；
不可能事件 $\emptyset$ 与任意随机事件 A 相互独立.

注意1：两事件相互独立与互不相容的区别

✓ “ A 与 B 互不相容”，指两事件不能同时发生，即 $AB = \emptyset$ 。

A 与 B 互不相容 $\Rightarrow P(AB) = 0$ ；但是 $P(AB) = 0 \not\Rightarrow A$ 与 B 互不相容

✓ “ A 与 B 相互独立”，指 A 是否发生不影响 B 发生的概率，即

$P(AB)=P(A)P(B)$ 或 $P(B|A) = P(B)$ ($P(A) > 0$)

注意2：设事件 A 与 B 满足 $P(A)P(B) \neq 0$

则互不相容与相互独立不能同时成立。

即 若事件 A 与 B 相互独立，则 $AB \neq \emptyset$ ；

若 $AB = \emptyset$ ，则事件 A 与 B 不相互独立。

(3) 三个事件的独立性

- 设 A 、 B 、 C 是三个随机事件，如果

$$\begin{cases} P(AB) = P(A)P(B) \\ P(BC) = P(B)P(C) \\ P(AC) = P(A)P(C) \\ P(ABC) = P(A)P(B)P(C) \end{cases}$$

四个等式缺一不可

则称 A 、 B 、 C 是**相互独立的随机事件**。

- 注意1：**在三个事件独立性的定义中，四个等式缺一不可。即前三个等式的成立不能推出第四等式的成立；反之，最后一个等式的成立也推不出前三个等式的成立。
- 注意2：**若 A 、 B 、 C 是相互独立的三个事件，则通过事件 B 、 C 运算得到的事件也与事件 A 相互独立

$$(A, B \cup C), (A, BC), (A, B - C), \\ (A, \overline{B \cup C}), (A, \overline{BC}), (A, \overline{B}\overline{C}) \dots$$

(4) n 个事件的独立性

- 设 $A_1, A_2, \dots, A_n$ 为 n 个随机事件，若下列等式成立

$$\left\{ \begin{array}{ll} P(A_i A_j) = P(A_i)P(A_j) & (1 \leq i < j \leq n) \\ P(A_i A_j A_k) = P(A_i)P(A_j)P(A_k) & (1 \leq i < j < k \leq n) \\ \dots \dots & \dots \\ P(A_1 A_2 \dots A_n) = P(A_1)P(A_2) \dots \dots P(A_n) & \dots \end{array} \right.$$

则称 $A_1, A_2, \dots, A_n$ 这 n 个随机事件相互独立。

☛ Bernoulli概型及 n 重Bernoulli试验，计算与之相关事件的概率

(1) Bernoulli试验：若随机试验 E 只有两个结果

- 一般地，我们将这两个结果即为 A 与 $\bar{A}$ ，分别称为“成功”与“失败”

(2) n 重Bernoulli试验：独立重复地进行 n 次Bernoulli试验

- “重复”：指每次试验中 A 发生的概率（即“成功”的概率）不变
- “独立”：指各次试验的结果相互独立

(3) n 重Bernoulli试验中恰好成功 k 次的概率

- 设在一次Bernoulli试验中,

$$P(A) = p, \quad P(\bar{A}) = 1 - p = q$$

- 事件 $B_{n,k} = \{n\text{重Bernoulli试验中事件}A\text{恰好发生}k\text{次}\}$ 的概率:

$$P(B_{n,k}) = C_n^k p^k (1 - p)^{n-k}, k = 0, 1, 2, \dots, n$$

第二章 随机变量及其分布

- 重要知识点
 - 分布函数的定义及性质
 - 离散型随机变量及其分布率
 - 两点分布、二项分布、泊松分布、几何分布、超几何分布
 - 泊松定理
 - 连续型随机变量的密度函数vs. 分布函数
 - 概率密度与分布函数之间关系及其运算
 - 常见的连续型随机变量分布：均匀分布、指数分布、正态分布
 - 随机变量的函数及其分布

随机事件



随机变量

样本空间；集合

例：{至少取出2个黑球}

实数；随机变量取值刻画随机事件

例：{ $X \geq 2$ }

定义： 设随机试验的样本空间是 $A = \{\omega\}$. $X = X(\omega)$ 是定义在样本空间 S 上的 **实值单值** 函数。称 $X = X(\omega)$ 为 **随机变量**。

常用的离散型随机变量

(1) Bernoulli分布

如果随机变量 X 的分布律为

$$P\{X = 0\} = 1 - p = q, \quad P\{X = 1\} = p$$

X	0	1
P	$1-p$	p

则称随机变量 X 服从参数为 p 的Bernoulli分布。


记作 $X \sim B(1, p)$ ，其中 $0 \leq p \leq 1$ 为参数。

概率背景：
进行一次Bernoulli试验，事件 A 是否发生

(2) 二项分布

如果随机变量 X 的分布律为

$$P\{X = k\} = C_n^k p^k (1 - p)^{n-k} \\ (k = 1, 2, \dots, n)$$



则称随机变量 X 服从参数为 (n, p) 的二项分布。

记作 $X \sim B(n, p)$ ，其中 $0 \leq p \leq 1$ 为参数。

说明：

- ① 显然，当 $n = 1$ 时 $X \sim B(1, p)$ 。此时， X 服从Bernoulli分布，即Bernoulli分布是二项分布的一个特例。
- ② 二项分布的概率背景：进行 n 重Bernoulli试验，设在每次试验中 $P(A) = p$, $P(\bar{A}) = 1 - p = q$ 。令 X 为在这Bernoulli试验中事件 A 发生的次数。则 $X \sim B(n, p)$ 。

(3) Poisson分布


如果随机变量 X 的分布律为

$$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}$$

$k = 1, 2, \dots$, 其中 $\lambda > 0$ 为常数

则称随机变量 X 服从参数为 λ 的Poisson分布。

记作 $X \sim P(\lambda)$, 其中 $\lambda > 0$ 为参数。



Poisson分布的应用

- ✓ Poisson分布是概率论中重要的分布之一；
- ✓ 自然界及工程技术中的许多随机指标都服从Poisson分布；
- ✓ 它多是出现在当 X 表示在一定的时间或空间内出现的事件个数这种场合。

□ **Poisson定理**: 设随机变量 $X_n (n = 1, 2, \dots)$ 服从**二项分布**, 其分布律为

$$P\{X_n = k\} = C_n^k p_n^k (1 - p_n)^{n-k}, \quad k = 0, 1, \dots, n$$



$$\lim_{n \rightarrow \infty} np_n = \lambda > 0$$

$$\lim_{n \rightarrow \infty} P\{X_n = k\} = \lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$$

□ **Poisson定理的应用**

- np 较小时, 用**Possion分布**近似二项分布进行计算。($n \geq 20, p \leq 0.05$ 时较好)
- 当 n 比较大, p 比较小时, 令 $\lambda = np$

$$P\{X = k\} = C_n^k p^k (1 - p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}$$



(4) 几何分布

如果随机变量 X 的分布律为


$$P\{X = k\} = q^{k-1}p$$

$$k = 1, 2, \dots,$$

其中 $p \geq 0$, $q \geq 0$, $p + q = 1$

则称随机变量 X 服从参数为 p 的几何分布。

概率背景： 在Bernoulli试验 $P(A) = p$, $P(\bar{A}) = q = 1 - p$ 试验进行到 A 首次出现为止，令 X 为所需试验次数，则 X 服从参数为 p 的几何分布。



(5) 超几何分布


如果随机变量 X 的分布律为

$$P\{X = k\} = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$$

$k = 1, 2, \dots, \min(M, n)$, 其中 M, N, n 均为自然数

则称随机变量 X 服从参数为 (M, N, n) 的超几何分布。

概率背景：一批产品有 N 件，其中有 M 件次品，其余 $N - M$ 件为正品。现从中取出 n 件。令 X 为取出 n 件产品中的次品数。则 X 服从参数为 (N, M, n) 的超几何分布。



(5) 超几何分布


- 👑 这个分布在涉及抽样的问题中常用，特别当 N 不大时。
- 👑 因为通常在抽样时，多是“无放回的”，这就与同时抽出的效果一样。
- 👑 如果是“有放回的抽”，结果是二项分布。
- 👑 若 n/N 很小，则放回与不放回差别不大。由此可见，在这种情况下超几何分布与二项分布很接近。
- 👑 确切地说，若 X 服从超几何分布，则当 n 固定， M/N 固定， $N \rightarrow$ 无穷大时， X 近似地服从二项分布。

常用的连续型随机变量

(1) 均匀分布

若随机变量 X 的密度函数为


$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{其它} \end{cases}$$



则称 X 服从区间 $[a, b]$ 上的均匀分布, 记作 $X \sim U[a, b]$ 。

分布函数


$$F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x < b, \\ 1, & x \geq b. \end{cases}$$



(2) 指数分布

若随机变量 X 的密度函数为


$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$



其中， $\lambda > 0$ 为常数，则称随机变量 X 服从参数为 λ 的指数分布，记作 $X \sim E(\lambda)$ 。

分布函数


$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$



(3) 正态分布

若随机变量 X 的密度函数为


$$\phi(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (-\infty < x < +\infty)$$



则称随机变量 X 服从参数为 (μ, σ^2) 的**正态分布**，记作
 $X \sim N(\mu, \sigma^2)$

分布函数

$$\Phi(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$



标准正态分布

□ 当正态分布 $N(\mu, \sigma^2)$ 中的 $\mu = 0$, $\sigma = 1$ 时, 这样的正态分布称为**标准正态分布**, 记为 $N(0, 1)$.

□ 标准正态分布的**概率密度**表示为



$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < +\infty$$

□ 标准正态分布的**分布**函数表示为

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt, \quad -\infty < x < +\infty$$

标准正态分布的重要公式

1. 若 $X \sim N(\mu, \sigma^2)$, 则 $Y = \frac{X - \mu}{\sigma} \sim N(0, 1)$.
2. $P\{c \leq X \leq d\} = \Phi\left(\frac{d - \mu}{\sigma}\right) - \Phi\left(\frac{c - \mu}{\sigma}\right)$.
3. $\Phi(-x) = 1 - \Phi(x)$.



标准正态分布的 3σ 准则

□ 由标准正态分布的查表计算可以求得, 当
 $X \sim N(0,1)$ 时

$$\mu \pm \sigma: P(|X| \leq 1) = 2 \Phi(1) - 1 = 0.6826$$

$$\mu \pm 2\sigma: P(|X| \leq 2) = 2 \Phi(2) - 1 = 0.9544$$

$$\mu \pm 3\sigma: P(|X| \leq 3) = 2 \Phi(3) - 1 = 0.9974$$

X 的取值几乎全部集中在 $[-3,3]$ 区间内, 超出这个范围的可能性仅占不到0.3%。

随机变量的函数的分布

(1) 离散型随机变量的函数的分布

□ 如果 X 是离散型随机变量, 其函数 $Y=g(X)$ 也是离散型随机变量。若 X 的分布律为

X	x_1	x_2	$\cdots$	x_k	$\cdots$
p_k	p_1	p_2	$\cdots$	p_k	$\cdots$

则 $Y = g(X)$ 的分布律为

$Y = g(X)$	$g(x_1)$	$g(x_2)$	$\cdots$	$g(x_k)$	$\cdots$
p_k	p_1	p_2	$\cdots$	p_k	$\cdots$

(2) 连续型随机变量的函数的分布

□ 如果 X 是连续型随机变量, 其函数 $Y=g(X)$ 也是连续型随机变量

□ Y 的概率密度计算:

- 根据 X 的密度函数 $f_X(x)$ 求出 Y 的分布函数

$$\begin{aligned} F_Y(y) &= P\{Y \leq y\} = P\{g(X) \leq y\} \\ &= \int_{g(x) \leq y} f_X(x) dx \quad (-\infty < x < +\infty) \end{aligned}$$

- 再对 $F_Y(y)$ 求导得到 Y 的密度函数

(2) 连续型随机变量的函数的分布

□ 若 $g(X)$ 是**严格单调函数**, 即 $g'(X) < 0$ 或 $g'(X) > 0$, 有

$$f_Y(y) = \begin{cases} f_X[h(y)]|h'(y)|, & \alpha < y < \beta \\ 0, & otherwise \end{cases}$$

其中, $\alpha = \min\{g(-\infty), g(+\infty)\}$, $\beta = \max\{g(-\infty), g(+\infty)\}$

□ 若 $g(x)$ 在**不相叠**的区间 $I_1, I_2, \dots$ 上逐段严格单调, 其反函数分别为 $h_1(x), h_2(x), \dots$ 均为**连续**函数, 那么 $Y = g(x)$ 是**连续型**随机变量, 其概率密度为

$$f_Y(y) = f_X[h_1(y)]|h'_1(y)| + f_X[h_2(y)]|h'_2(y)| + \dots, y \in (\alpha, \beta)$$

直观理解: $f_Y(y)\Delta y = f_X[h(y)]\Delta x$

□ 解题小技巧

- 求 $Y = g(X)$ 的概率密度

通用步骤

1. 确定 Y 的取值范围
2. 写出取值范围内 Y 的分布函数 $F_Y(y) = P\{Y \leq y\}$
3. 对 $F_Y(y)$ 求导得到 $f_Y(y)$
4. 写出 $f_Y(y)$ 在 $(-\infty, +\infty)$ 上的完整表达式, 检查边界处“=”的取法


$g(X)$ 单调

$$f_Y(y) = \begin{cases} f_X[h(y)]|h'(y)|, & \alpha < y < \beta \\ 0, & \text{otherwise} \end{cases}$$

$$\alpha = \min\{g(-\infty), g(+\infty)\},$$
$$\beta = \max\{g(-\infty), g(+\infty)\}$$


$g(X)$ 逐段单调

$$f_Y(y) = f_X[h_1(y)]|h'_1(y)| + f_X[h_2(y)]|h'_2(y)| + \dots$$

****小结: 常用概率分布****

第三章 多维随机变量及其分布

- 重要知识点
 - 二维随机变量的分布
 - 有关概率的计算和随机变量的独立性
 - 边缘概率
 - 条件概率
 - 随机变量函数的分布



二维随机变量： 设 E 是一个随机试验，它的样本空间是 $S=\{e\}$ ，设 $X=X(e)$ 和 $Y=Y(e)$ 是定义在 S 上的随机变量。由它们构成的一个向量 (X, Y) ，叫做二维随机向量，或二维随机变量。

二维随机变量

条件分布

条件分
布函数

条件分
布律

条件概
率密度

联合分布

联合分
布函数

联合分
布律

联合概
率密度

边缘分布

边缘分
布函数

边缘分
布律


边缘概
率密度

随机变量的相互独立性

随机变量的函数的分布

推广至多维

贝叶斯公式



二维离散型随机变量的分布律

- 若二维随机变量 (X, Y) 的取值是有限个或可列无穷个，则称 (X, Y) 为二维离散型随机变量
- 设 (X, Y) 二维离散型随机变量 X 的取值为 $x_1, x_2, \dots, x_i, \dots$ ， Y 的取值为 $y_1, y_2, \dots, y_i, \dots$ ，则称 $p_{ij} = P\{X = x_i, Y = y_j\}, (i, j = 1, 2, \dots)$ 为二维离散型随机变量 (X, Y) 的联合分布律

$Y \backslash X$	$x_1,$	$x_2,$	$\dots,$	$x_i,$
y_1	$p_{11},$	$p_{21},$	$\dots,$	$p_{i1},$
y_2	$p_{12},$	$p_{22},$	$\dots,$	$p_{i2},$
$\vdots$	$\dots$	$\vdots$	$\vdots$	$\vdots$
y_i	$p_{1i},$	$p_{2i},$	$\dots,$	$p_{ii},$
$\vdots$	$\dots$	$\vdots$	$\vdots$	$\vdots$

- 离散型随机变量 (X, Y) 的分布函数为

$$F(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{ij},$$

对一切满足 $x_i \leq x, y_j \leq y$ 的 i, j 项求和

二维连续型随机变量的概率密度

(1) **定义**：对于二维随机变量 (X, Y) 的分布函数 $F(x, y)$ ，如果存在**非负实函数** $f(x, y)$ ，使得对于**任意**的**实数** x, y 有

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(u, v) du dv,$$

- 则称 (X, Y) 是**连续型**的二维随机变量
- 函数 **$f(x, y)$** 称为二维随机变量 **(X, Y) 的概率密度**，或称为 **X 和 Y 的联合概率密度**

二维连续型随机变量的概率密度

(2) 性质

1⁰ $f(x, y) \geq 0$; 非负性

2⁰ $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = F(\infty, \infty) = 1$; 规范性

3⁰ 若 $f(x, y)$ 在点 (x, y) 连续, 则有

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y).$$

4⁰ 设 G 是平面上的一个区域, 点 (X, Y) 落在 G 内的概率为:

$$P\{(X, Y) \in G\} = \iint_G f(x, y) dx dy.$$

应用: 估计积分


二维连续型随机变量的概率密度

(3) 几何意义

- $z = f(x, y)$ 表示空间的一个曲面


$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$$

表示介于**曲面** $f(x, y)$ 和 **xoy 平面**之间空间区域的**体积**等于1



$$\square P\{(X, Y) \in G\} = \iint_G f(x, y) dx dy$$

的值等于以 **G** 为底，**曲面** $z = f(x, y)$ 为顶面的柱体**体积**




二维连续型随机变量的概率密度

(4) 常用分布

- 二维均匀分布**：设 D 是平面上的有界区域，其面积为 A 。如果二维随机变量 (X, Y) 的密度函数为

$$f(x, y) = \begin{cases} \frac{1}{A}, & (x, y) \in D \\ 0, & (x, y) \notin D \end{cases}$$



则称二维随机变量 (X, Y) 服从区域 D 上的**均匀分布**。


二维连续型随机变量的概率密度

(4) 常用分布

- **二维正态分布**: 设二维随机变量 (X, Y) 的密度函数为 $f(x, y)$

$$= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{(x-\mu_1)^2/\sigma_1^2 - 2\rho(x-\mu_1)(x-\mu_2)/\sigma_1\sigma_2 + (x-\mu_2)^2/\sigma_2^2}{2(1-\rho^2)}}$$

□ 则称随机变量 (X, Y) 服从参数为 $(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的正态分布, 记作 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 其中 $-\infty < \mu_i < +\infty$ ($i=1, 2$), $\sigma_i > 0$ ($i=1, 2$), $-1 < \rho < 1$.




边缘分布函数

(1) 边缘分布定义

- 如果 (X, Y) 是一个二维随机变量，则它的分量 X (或 Y) 是一维随机变量。
- 因此，分量 X (或 Y) 也有分布，我们称 X (或 Y) 的分布为二维随机变量 (X, Y) 关于 X (或 Y) 的边缘分布。

边缘分布也称为边沿分布或边际分布。



思考：二维正态分布 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ $\xrightarrow{\neq}$ $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$

☛ 边缘分布函数

1) 已知联合分布函数求边缘分布函数

设二维随机变量 (X, Y) 的分布函数为 $F(x, y)$, 则分量 X 的分布函数为

$$\begin{aligned} F_X(x) &= P\{X \leq x\} = P\{X \leq x, Y \leq +\infty\} \\ &= \lim_{y \rightarrow +\infty} F(x, y) = F(x, +\infty) \end{aligned}$$

分量 Y 的分布函数为

$$\begin{aligned} F_Y(y) &= P\{Y \leq y\} = P\{X \leq +\infty, Y \leq y\} \\ &= \lim_{x \rightarrow +\infty} F(x, y) = F(+\infty, y) \end{aligned}$$

边缘分布函数

2) 已知联合分布律求边缘分布律

X和Y的边缘分布律也可以由下表表示

$X \backslash Y$	y_1	y_2	...	y_j	...	$p_{i\cdot}$
x_1	p_{11}	p_{12}	...	Σp_{1j}	...	$p_{1\cdot}$
x_2	p_{21}	p_{22}	...	p_{2j}	...	$p_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
x_i	p_{i1}	p_{i2}	...	p_{ij}	...	$p_{i\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
$p_{\cdot j}$	$p_{\cdot 1}$	$p_{\cdot 2}$	...	$p_{\cdot j}$	...	1

☛ 边缘分布函数

3) 已知联合密度函数求边缘密度函数

若 (X, Y) 的联合密度函数为 $f(x, y)$, 则随机变量 X 的边缘密度函数为

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) \, dy$$

随机变量 Y 的边缘密度函数为

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) \, dx$$

离散型随机变量的条件分布

设 (X, Y) 是二维离散型随机变量,

对于固定的 j , 若 $P\{Y = y_j\} > 0$, 则称

$$P\{X = x_i | Y = y_j\} = \frac{P\{X=x_i, Y=y_j\}}{P\{Y=y_j\}} = \frac{p_{ij}}{p_{\cdot j}}, i = 1, 2, \dots$$

为在 $Y = y_j$ 条件下随机变量 X 的条件分布律。

对于固定的 i , 若 $P\{X = x_i\} > 0$, 则称

$$P\{Y = y_j | X = x_i\} = \frac{P\{X=x_i, Y=y_j\}}{P\{X=x_i\}} = \frac{p_{ij}}{p_{i \cdot}}, j = 1, 2, \dots$$

为在 $X = x_j$ 条件下随机变量 Y 的条件分布律。

连续型随机变量的条件分布

当 $f_Y(y) > 0$ 时, 随机变量 X 在 $Y = y$ 条件下的条件密度函数为

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$


当 $f_X(x) > 0$ 时, 随机变量 Y 在 $X = x$ 条件下的条件密度函数为

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$$

注意1: $P(X \leq x|Y = y) \approx P(X \leq x|y < Y \leq y + \epsilon) = \frac{P(X \leq x, y < Y \leq y + \epsilon)}{P(y < Y \leq y + \epsilon)}$

注意2: $P(X \leq x|Y = y) = \int_{-\infty}^x f_{X|Y}(x|y) dx = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} dx$
 $P(X \leq x|Y \leq y) = \frac{P(X \leq x, Y \leq y)}{P(Y \leq y)} = \frac{\int_{-\infty}^x \int_{-\infty}^y f(x, y) dx dy}{\int_{-\infty}^y f_Y(y) dy}$

联合分布、边缘分布、条件分布的关系



$$f(x, y) = f_X(x)f_{Y|X}(y|x) = f_Y(y)f_{X|Y}(x|y)$$

二维正态分布 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho) \xRightarrow{\text{red arrow}} X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$

连续型随机变量和 $Z=X+Y$ 的分布

- 设二维连续型随机变量 (X, Y) 的联合密度函数为 $f(x, y)$, 则 $Z = X + Y$ 的密度函数为

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx \quad \text{或} \quad f_Z(z) = \int_{-\infty}^{+\infty} f(z-y, y) dy$$

□如果随机变量 X 和 Y 相互独立, 即 $f(x, y) = f_X(x)f_Y(y)$, 此时 $Z = X + Y$ 的密度函数为

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x)f_Y(z-x) dx$$

或

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(z-y)f_Y(y) dy$$

$$f_X(x) * f_Y(y)$$

卷积公式!

相互独立的正态分布随机变量的和的分布

- 如果随机变量 X 和 Y 相互独立, 且 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 令 $Z = X + Y$, 则

$$Z \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

- 如果随机变量 $X_1, X_2, \dots, X_n$ 相互独立, 且 $X_i \sim N(\mu_i, \sigma_i^2)$, ($i = 1, 2, \dots, n$), $a_1, a_2, \dots, a_n$ 为 n 个实常数, 则 $Z = \sum_{i=1}^n a_i X_i$ 满足

$$Z \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

连续型随机变量函数的分布

(1) **问题：** 设 (X, Y) 是二维连续型随机变量，其联合密度函数为 $f(x, y)$ ，求随机变量函数 $Z = g(X, Y)$ 的密度函数 $f_Z(z)$ 。

(2) 求解步骤

1. 先求随机变量函数 $Z = g(X, Y)$ 的**分布**函数

$$F_Z(z) = P(Z \leq z)$$

2. 再求随机变量函数 $Z = g(X, Y)$ 的**密度**函数

$$f_Z(z) = F'_Z(z)$$

连续型随机变量函数的分布

(3) 几种常见函数的分布

$$Z = X + Y \rightarrow f_Z(z) = \int_{-\infty}^{\infty} f(x, z - x) dx$$

$$Z = Y/X \rightarrow f_Z(z) = \int_{-\infty}^{\infty} |x| f(x, xz) dx$$

$$Z = XY \rightarrow f_Z(z) = \int_{-\infty}^{\infty} \left| \frac{1}{x} \right| f\left(x, \frac{z}{x}\right) dx$$

■ 直观理解

$$F(z) = \iint_D f(x, y) dx dy$$

$$\text{关键步骤: } dy \rightarrow \frac{\partial y(x, z)}{\partial z} dz$$

连续型随机变量函数的分布

连续函数

• 一般步骤：

1. 先求随机变量函数 $Z = g(X, Y)$ 的分布函数

$$F_Z(z) = P(Z \leq z) = P\{g(X, Y) \leq z\} = \iint_{g(x, y) \leq z} f(x, y) dx dy$$

2. 再求随机变量函数 $Z = g(X, Y)$ 的密度函数 $f_Z(z) = F'_Z(z)$

• 难点：标明 z 的定义域；确定积分区间

1. 在 $x-y$ 坐标系中画出 x, y 的取值范围
2. 画 $z = g(x, y)$ 的等高线
3. 划分 z 的定义域区间，使得同一区间内，积分上下限表达方式一致
4. 每个 z 的定义域划分中，积分计算 $F_Z(z)$

参考
步骤

连续型随机变量函数的分布

• 几种常见函数的分布

$$Z = X + Y \rightarrow f_Z(z) = \int_{-\infty}^{\infty} f(x, z-x) dx$$

$$Z = Y/X \rightarrow f_Z(z) = \int_{-\infty}^{\infty} |x| f(x, xz) dx$$

$$Z = XY \rightarrow f_Z(z) = \int_{-\infty}^{\infty} \left| \frac{1}{x} \right| f\left(x, \frac{z}{x}\right) dx$$

□ 公式法（适用于上面三种常见的函数）

参考步骤

1. 选定内变量（例如Y），写出 $f_Z(z) \neq 0$ 时 $f_Z(z)$ 的表达式。表达式中不再有Y，仅有x和z，并需要对x积分
2. 确定 $f_Z(z) \neq 0$ 时，Z和X的取值范围
3. 在 $z-x$ 坐标系下，画出Z和X的取值范围
4. 根据3中的图，确定x的积分范围，进行积分
5. 写出最后结果，标明z的定义域

连续型随机变量函数的分布

(4) 易错点

- 区分分布函数、分布律、概率密度
 - 分布函数： $F(x, y) = P(X \leq x, Y \leq y)$,
 - 分布律（离散型）： $p_{ij} = P(X = x_i, Y = y_j)$
 - 概率密度函数（连续型）： $f(x, y)$
- 概率密度函数的定义域
 - 不漏写定义域：任何一个概率密度函数，都需标明变量的定义域。
 - 求谁的密度，写谁的定义域

第四章 随机变量的数字特征

- 重要知识点
 - 数学期望、方差、相关系数的性质和计算
 - 随机变量函数的数字特征

离散型随机变量的数学期望

- 设**离散型**随机变量 X 的分布律为

$$P\{X = x_k\} = p_k, k = 1, 2, \dots$$

若级数 $\sum_{k=1}^{\infty} x_k p_k$ **绝对收敛**，则称 $\sum_{k=1}^{\infty} x_k p_k$ 为**离散型**随机变量 X 的**数学期望**。记为 $E(X)$ ，即

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

$$\sum_{k=1}^{\infty} |x_k| p_k < +\infty$$

连续型随机变量的数学期望

- 设**连续型**随机变量 X 的概率密度为 $f(x)$ ，若积分 $\int_{-\infty}^{+\infty} xf(x)dx$ **绝对收敛**，则称此积分值为**连续型**随机变量 X 的**数学期望**。记为 $E(X)$ ，即

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx$$

$$\int_{-\infty}^{+\infty} |x|f(x)dx < +\infty$$

随机变量函数的数学期望

(1) 离散型随机变量函数

若 $Y = g(X)$, 且 $P\{X = x_k\} = p_k$, $k = 1, 2, \dots$, 且 $\sum_{k=1}^{\infty} g(x_k)p_k$ 绝对收敛, 则 Y 的数学期望为

$$E(g(X)) = \sum_{k=1}^{\infty} g(x_k)p_k$$

(2) 连续型随机变量函数

连续型随机变量 X 的概率密度为 $f(x)$, 若 $Y = g(X)$, 且 $\int_{-\infty}^{\infty} g(x)f(x)dx$ 绝对收敛, 则 Y 的数学期望为

$$E(g(X)) = \int_{-\infty}^{+\infty} g(x)f(x)dx$$

数学期望的性质

1. 设 C 是常数, 则有 $E(C) = C$.

2. 设 X 是一个随机变量, C 是常数, 则有

$$E(CX) = CE(X).$$

3. 设 X, Y 是两个随机变量, 则有

$$E(X + Y) = E(X) + E(Y).$$

期望：加法不需要独立性

$$E(aX + bY + c) = aE(X) + bE(Y) + c$$

4. 设 X, Y 是相互独立的随机变量, 则有

$$E(XY) = E(X)E(Y).$$

期望：乘法需要独立性

二维随机变量的数学期望

- 设 (X, Y) 为二维随机变量, 若 $E(X), E(Y)$ 都存在, 则 X 与 Y 的期望分别定义为

$$E(X) = \begin{cases} \sum_i \sum_j x_i p_{ij} & \text{离散型} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f(x, y) dx dy & \text{连续型} \end{cases}$$

(X, Y) 的概率分布律为 p_{ij}

(X, Y) 的概率密度为 $f(x, y)$

$$E(Y) = \begin{cases} \sum_i \sum_j y_i p_{ij} & \text{离散型} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y f(x, y) dx dy & \text{连续型} \end{cases}$$

(X, Y) 的概率分布律为 p_{ij}

(X, Y) 的概率密度为 $f(x, y)$

↑ 利用联合分布求单个变量的期望

二维随机变量函数的数学期望

- 若 X, Y 为**离散型**随机变量, $g(x, y)$ 是二元函数, (X, Y) 的联合概率分布律为 p_{ij} , 且 $E[g(X, Y)]$ 存在, 则
$$E[g(X, Y)] = \sum_i \sum_j g(x_i, y_j) p_{ij}$$
- 若 X, Y 为**连续型**随机变量, $g(x, y)$ 是二元函数, (X, Y) 的联合分布密度为 $f(x, y)$, 且 $E[g(X, Y)]$ 存在, 则
$$E[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$$

方差

(1) **定义**: 设 X 是一个随机变量, 若 $E\{[X - E(X)]^2\}$ 存在, 则称 $E\{[X - E(X)]^2\}$ 是 X 的**方差**, 记作 $D(X)$ 或 $Var(X)$, 即

$$D(X) = Var(X) = E\{[X - E(X)]^2\}$$

方差的
非负性

• 称 $\sqrt{D(X)}$ 为**标准差**或**均方差**, 记作 $\sigma(X)$ 。

(2) 方差的计算

- 离散型随机变量 $D(X) = \sum_{k=1}^{\infty} [x_k - E(X)]^2 p_k$
- 连续型随机变量 $D(X) = \int_{-\infty}^{+\infty} [x_k - E(X)]^2 f(x) dx$
- 常用计算公式 $D(X) = E\{[X - E(X)]^2\} = E(X^2) - [E(X)]^2$

☛ 方差的性质

1. 设 C 是常数, 则有 $D(C) = 0$.

2. 设 X 是一个随机变量, C 是常数, 则有
$$D(CX) = C^2 D(X).$$

3. 设 X, Y **相互独立**, $D(X), D(Y)$ 存在, 则有

$$D(X \pm Y) = D(X) + D(Y). \quad \text{方差: 加法需要独立性}$$

否则, $D(X \pm Y) = D(X) + D(Y) \pm 2(E(XY) - E(X)E(Y))$

4. $D(X) = 0$ 的**充要条件**是 X 以概率1取常数 C , 即

$$D(X) = 0 \iff P(X = C) = 1$$

期望: 可**加性****不要求**独立、可**乘性**要求**独立**


方差: 可**加性**要求**独立**

切比雪夫(Chebyshev)不等式

□ 设随机变量 X 数学期望 $E(X) = \mu$ **存在**, 方差 $D(X) = \sigma^2$, 则对于 **任意正数** ϵ , 则有

$$P\{|X - \mu| \geq \epsilon\} \leq \frac{\sigma^2}{\epsilon^2} \Leftrightarrow P\{|X - \mu| < \epsilon\} \geq 1 - \frac{\sigma^2}{\epsilon^2}$$

$$\begin{aligned} P\{|X - \mu| \geq \epsilon\} &= \int_{|x - \mu| \geq \epsilon} f(x) dx \\ &\leq \int_{|x - \mu| \geq \epsilon} \frac{|x - \mu|^2}{\epsilon^2} f(x) dx \leq \frac{\sigma^2}{\epsilon^2} \end{aligned}$$



☛ 协方差与相关系数

- 随机变量 X 与 Y 的**协方差**

$$\mathbf{Cov}(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$$

- 协方差常用计算方法

$$\mathbf{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

- 随机变量 X 与 Y 的**相关系数**

$$\rho_{XY} = \frac{\mathbf{Cov}(X, Y)}{\sqrt{D(X)} \cdot \sqrt{D(Y)}}$$

☛ 协方差的性质

$$1. \text{Cov}(X, Y) = \text{Cov}(Y, X).$$

$$2. \text{Cov}(aX, bY) = ab\text{Cov}(X, Y) \quad (a, b \text{ 为常数})$$

$$3. \text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y).$$

$$\text{Cov}(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$$

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

$$D(X \pm Y) = D(X) + D(Y) \pm 2\text{Cov}(X, Y)$$

按方差定义展开即得

☛ 相关系数的性质

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \cdot \sqrt{D(Y)}}$$

1) $|\rho_{XY}| \leq 1$

2) $|\rho_{XY}| = 1$ 的充要条件是：存在常数 a 、 b ，使得

$$P\{Y = a + bX\} = 1$$

Y 可被 X 线性表出

□ **相关系数**只能说明两个变量之间是否存在**线性关系**，不能得出两个变量是否独立。

独立 $\Rightarrow$ 不相关； 不相关 $\nRightarrow$ 独立

X 、 Y 相互独立时， $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0$

常见分布的数学期望与方差

分 布	参 数	数学期望	方差
两点分布	$0 < p < 1$	p	$p(1-p)$
二项分布	$n \geq 1,$ $0 < p < 1$	np	$np(1-p)$
泊松分布	$\lambda > 0$	λ	λ
均匀分布	$a < b$	$(a+b)/2$	$(b-a)^2/12$
指数分布	$\theta > 0$	θ	θ^2
正态分布	$\mu, \sigma > 0$	μ	σ^2

第五章 大数定律与中心极限定理

常见的（弱）大数定律

□ 什么时候（弱）大数定律成立？

- 设随机变量序列 $\{X_n\}$

	$\{X_n\}$ 分布	$\{X_n\}$ 是否两两独立	$E(X_i)$	$D(X_i)$
Chebyshev大数定律	—	是	存在	存在且有界
Poisson大数定律	0-1分布	是	存在	存在且有界
Bernoulli大数定律	同分布 0-1分布	是	存在	存在且有界
Khinchin大数定律	同分布	是	存在	可以不存在
Markov大数定律	—	否	存在	$\lim_{n \rightarrow \infty} D\left(\frac{1}{n} \sum_{k=1}^n X_k\right) = 0$

常见的中心极限定理

□ 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 两两独立

	$\{X_n\}$ 分布	$E(X_i)$	$D(X_i)$	Y_n
独立同分布的中心极限定理	同分布	μ	$\sigma_k^2 > 0$	$\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$
棣莫佛 - 拉普拉斯定理	同分布 0-1分布	$p \in (0,1)$	$p - p^2$	$\frac{\sum_{k=1}^n X_k - np}{\sqrt{np(1-p)}}$
李雅普诺夫定理	—	μ_i	$\sigma_k^2 > 0$; 且存在 $\delta > 0$, 使得当 $n \rightarrow \infty$ 时, $\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{ X_k - \mu_k ^{2+\delta}\} \rightarrow 0$	$\frac{\sum_{k=1}^n X_k - (\sum_{k=1}^n \mu_k)}{\sqrt{D(\sum_{k=1}^n X_k)}}$

考试范围：第一章至第五章

考试时间：2025年11月25日（周二）
8:30-10:10

考试地点：教三楼119

预祝期中考试顺利！